

УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



ВЕБ АПЛИКАЦИЈА ЗА ПРЕДИКЦИЈУ ОДГОВОРА НА ТЕРАПИЈУ КОД ПАЦИЈЕНАТА ПРИМЕНОМ РАЗЛИЧИТИХ МОДЕЛА МАШИНСКОГ УЧЕЊА

Завршни рад

Студијски програм: Електротехника и рачунарство

Модул: Рачунарство и информатика

Студент:
Светислав Вељковић бр.инд. 19083

Ментор:
Проф.др. Валентина Нејковић

Ниш, септембар 2026. године

Универзитет у Нишу

Електронски Факулет

Веб апликација за предикцију одговора на терапију код пацијената применом различитих модела машинског учења

Web Application for Predicting Patient Response to Therapy Using Different Machine Learning Models

Завршни рад

Студијски програм: Електротехника и рачунарство

Модул: Рачунарство и информатика

Студент: Светислав Вељковић бр.инд. 19083

Ментор: Проф.др. Валентина Нејковић

Задатак: Развити и испитати систем за анализу и предикцију одговора на терапију применом метода машинског учења над стварним клиничким подацима контролног крака SQUIRE студије. Посебну пажњу посветити квалитету и временском контексту мерних података, спречавању цурења информација, упоредној евалуацији алгоритама и реализацији истраживачке веб-апликације.

Датум пријаве рада: 16.07.2026.

Датум предаје рада: 17.09.2026.

Датум одбране рада: 22.09.2026.

Комисија за оцену и одбрану:

1. Проф. др Валентина Нејковић, Председник Комисије

2. Проф. др Наталија Стојановић, Члан

3. Проф. Др Сузана Стојковић, Члан

САДРЖАЈ

1. УВОД ... 8
2. ПРОБЛЕМ ПРЕДИКЦИЈЕ ОДГОВОРА И СРОДНИ РАДОВИ ... 10
2.1. Предиктивни модели као информатички системи ... 10
2.2. Заједнички методолошки изазови ... 10
2.3. Позиционирање овог рада ... 11
3. ОСНОВЕ МАШИНСКОГ УЧЕЊА И ПРЕДИКТИВНОГ МОДЕЛОВАЊА ... 12
3.1. Надгледано учење и класификација ... 12
3.2. Тренинг, тест и унакрсна валидација ... 12
3.3. Overfitting, underfitting и цурење података ... 12
3.4. Недостајуће вредности и кодирање ... 13
3.5. Неуравнотеженост класа ... 13
3.6. Калибрација вероватноће ... 13
3.7. Избор прага и цена грешке ... 14
3.8. Хиперпараметри и контролисана претрага ... 14
4. КОРИШЋЕНИ МОДЕЛИ И МЕТРИКЕ ... 16
4.1. Logistic Regression ... 16
4.2. Elastic Net Logistic Regression ... 16
4.3. Random Forest ... 16
4.4. Support Vector Machine ... 16
4.5. XGBoost ... 17
4.6. Матрица конфузије, дискриминација и калибрација ... 17
5. СОФТВЕРСКА ИМПЛЕМЕНТАЦИЈА СИСТЕМА МАШИНСКОГ УЧЕЊА 18
5.1. Организација аналитичког решења ... 18
5.2. Дефинисање улаза и контролисан избор атрибута ... 18
5.3. Pipeline за претпроцесирање ... 19
5.4. Подела података и репродуктивност експеримента ... 19
5.5. Јединствен оквир за пет модела ... 20
5.6. Израчунавање метрика и чување резултата ... 20
5.7. Избор финалног модела без увида у тест резултат ... 21
5.8. Серијализација, deployment модел и метаподаци ... 21
5.9. SHAP анализа и локално објашњење ... 22
5.10. Рачунарска сложеност и практичне разлике модела ... 22
6. СКУП ПОДАТАКА И ФОРМИРАЊЕ КОХОРТЕ ... 24
6.1. Студија SQUIRE ... 24
6.2. Структура достављених табела ... 24
6.3. Дефинисање циљне променљиве ... 25

6.4. Избор предиктора ... 25
7. ЕКСПЛОРАТИВНА АНАЛИЗА И ПРЕТПРОЦЕСИРАЊЕ ... 26
7.1. Опис моделске кохорте ... 26
7.2. Недостајуће вредности ... 27
7.3. Нумеричке расподеле и униваријантна поређења ... 28
7.4. Корелације ... 29
8. РАЗВОЈ И ЕВАЛУАЦИЈА МОДЕЛА ... 31
8.1. Експериментални дизајн ... 31
8.2. Резултати унакрсне валидације ... 31
8.3. Комплетна евалуација на независном тест скупу ... 31
8.4. Калибрација предвиђених вероватноћа ... 34
8.5. Неизвесност и избор финалног модела ... 34
8.6. SHAP анализа изабраног модела ... 35
9. РАЗВОЈ ВЕБ-АПЛИКАЦИЈЕ ... 38
9.1. Циљ и архитектура система ... 38
9.2. Регистрација, пријава и улоге корисника ... 38
9.3. Модел података и SQLite база ... 38
9.4. Регистар пацијената и временска линија ... 39
9.5. Извршавање процене и конзистентност pipeline-а ... 39
9.6. Локално објашњење резултата ... 40
9.7. Проналажење сличних случајева ... 40
9.8. Извештај, историја и audit траг ... 40
9.9. Валидација и безбедносна ограничења ... 41
9.10. Тестирање интегрисаног система ... 41
9.11. Пројектовање интерфејса и даљи развој ... 41
10. ДИСКУСИЈА ... 43
11. ЗАКЉУЧАК ... 45
ЛИТЕРАТУРА ... 46

САЖЕТАК

Предмет овог рада је развој и евалуација репродуктивног поступка машинског учења за предикцију одговора на терапију на основу структурираних података доступних пре исхода. Поступак је реализован као студија случаја над деидентификованим индивидуалним подацима контролног крака студије SQUIRE, за пацијенте са планоцелуларним недробноћелијским карциномом плућа у стадијуму IV који су примали гемцитабин и цисплатин. Полазни скуп садржи 549 записа у табели на нивоу испитаника, од којих је 548 припадало популацији предвиђеној за анализу ефикасности. Циљна променљива формирана је на основу најбољег укупног одговора према критеријумима RECIST 1.0: потпун и делимичан одговор обједињени су у класу *Responder*, а стабилна и прогресивна болест у класу *Non-responder*. Записи са недефинисаним или непроцењивим исходом нису произвољно сврставани ни у једну класу. Коначну моделску кохорту чинило је 477 пацијената, од којих 158 одговорних и 319 неодговорних на терапију.

Посебна пажња посвећена је спречавању цурења података. Као предиктори коришћене су искључиво демографске, клиничке и лабораторијске карактеристике доступне пре почетка или на почетку терапије. Развијени су модели Logistic Regression, Elastic Net Logistic Regression, Random Forest, Support Vector Machine и XGBoost. Претпроцесирање је обједињено са моделом у јединствену scikit-learn процедуру, а избор хиперпараметара извршен је петоструком стратификованом унакрсном валидацијом искључиво на тренинг скупу. Независни тест скуп обухватио је 96 пацијената.

Резултати су показали умерену и међусобно сличну дискриминативну способност модела, уз широку неизвесност због величине тест скупа. Elastic Net Logistic Regression остварила је највиши средњи CV ROC AUC од 0,540 и изабрана је без увида у тест резултате. На тест скупу њен ROC AUC износио је 0,544, PR AUC 0,406, sensitivity 0,531 и balanced accuracy 0,523. За свих пет модела приказани су Brier score, ECE и калибрационе криве, а изабрани модел додатно је анализиран SHAP методом. Резултати представљају методолошки валидирану основу за даље унапређење, али не и клинички валидиран систем.

ABSTRACT

This thesis develops and evaluates a reproducible machine-learning workflow for predicting treatment response from structured information available before the outcome. The workflow is implemented as a case study using de-identified individual patient data from the control arm of the SQUIRE clinical trial: patients with stage IV squamous non-small-cell lung cancer treated with gemcitabine plus cisplatin. The subject-level table contained 549 records, of which 548 belonged to the intended efficacy population. The binary target was derived from Best Overall Response under RECIST 1.0: complete and partial responses formed the *Responder* class, while stable and progressive disease formed the *Non-responder* class. Records with undefined or non-evaluable outcomes were excluded rather than assigned arbitrarily. The final modelling cohort included 477 patients: 158 responders and 319 non-responders.

Data leakage prevention was treated as a central methodological requirement. Only demographic, clinical and laboratory variables available before or at treatment initiation were used as predictors. Logistic Regression, Elastic Net Logistic Regression, Random Forest, Support Vector Machine and XGBoost were evaluated using identical preprocessing pipelines and five-fold stratified cross-validation on the training data. The independent test set contained 96 patients.

Elastic Net Logistic Regression achieved the highest mean cross-validated ROC AUC (0.540) and was selected without inspecting the test results. On the held-out test set it achieved ROC AUC 0.544, PR AUC 0.406, sensitivity 0.531 and balanced accuracy 0.523. Brier score, expected calibration error and calibration curves were reported for all five models. The selected model was further interpreted using global and local SHAP analyses. The results provide a transparent basis for further model development, while the system remains a research prototype without clinical validation.

СПИСАК КОРИШЋЕНИХ СКРАЋЕНИЦА И ОЗНАКА

Табела 1. Списак коришћених скраћеница и ознака.

Скраћеница	**Значење**
ADaM	Analysis Data Model
API	Application Programming Interface
CR	Complete Response — потпун одговор
CV	Cross-Validation — унакрсна валидација
ECOG	Eastern Cooperative Oncology Group performance status
EDA	Exploratory Data Analysis — експлоративна анализа података
F1	Хармонијска средина precision и recall метрике
HTTP	Hypertext Transfer Protocol
JSON	JavaScript Object Notation
ML	Machine Learning — машинско учење
NSCLC	Non-Small-Cell Lung Cancer — недробноћелијски карцином плућа
PD	Progressive Disease — прогресивна болест
PR	Partial Response — делимичан одговор
RECIST	Response Evaluation Criteria in Solid Tumors
ROC AUC	Area Under the Receiver Operating Characteristic Curve
SD	Stable Disease — стабилна болест
SVM	Support Vector Machine
UI	User Interface — кориснички интерфејс
ECE	Expected Calibration Error — очекивана грешка калибрације
SHAP	SHapley Additive exPlanations

1. УВОД

Одлуке о избору терапије често се доносе на основу више истовремено доступних информација: демографских података, претходне историје, функционалног стања, лабораторијских резултата, карактеристика обољења и искуства стручњака. Пацијенти са формално сличном дијагнозом и истим терапијским режимом ипак могу имати различите исходе. Због тога је предикција одговора на терапију важан пример проблема у којем није довољно посматрати један показатељ, већ је потребно испитати заједнички образац већег броја карактеристика.

Машинско учење пружа скуп метода за изградњу предиктивних модела на основу примера са познатим исходом. Код надгледаног учења алгоритам процењује везу између улазних атрибута и циљне променљиве, а затим научени образац примењује на нове примере. Такав приступ се може користити у различитим областима: за процену одговора на лек, ризика од нежељеног догађаја, вероватноће поновног јављања болести или успеха одређене интервенције. Конкретна болест и терапија одређују значење атрибута и исхода, али су основни информатички проблеми заједнички: квалитет података, правилна дефиниција циља, спречавање цурења информација, избор модела и поуздана евалуација.

Потенцијална предност машинског учења је способност да истовремено обради више променљивих и препозна односе који нису видљиви из једноставног поређења појединачних атрибута. Међутим, сложенији алгоритам не гарантује користан модел. Ако је узорак мали, исход непоуздано дефинисан или су улазни подаци настали после догађаја који се предвиђа, алгоритам може научити случајности или недозвољене информације. Зато квалитет предиктивног система зависи барем подједнако од формулације проблема и експерименталног поступка као од избора класификатора.

Савремене смернице за извештавање о клиничким предиктивним моделима наглашавају јасан опис извора података, популације, исхода, предиктора, недостајућих вредности, поступка евалуације и ограничења. Ови принципи су релевантни и за информатички завршни рад јер омогућавају да имплементација буде проверљива и да се резултати не представе убедљивије него што подаци дозвољавају. Посебно је важно раздвојити развој модела од његове независне евалуације и сачувати исти поступак претпроцесирања током обуке и примене.

Овај рад разматра општи поступак развоја система за бинарну предикцију одговора на терапију, а затим га реализује над једним јавно доступним клиничким скупом. Као студија случаја коришћени су подаци контролног крака студије SQUIRE, јер садрже структуриране демографске, клиничке и лабораторијске податке, као и стандардизовану процену исхода. Анализа је ограничена на пацијенте са планоцелуларним недробноћелијским карциномом плућа у стадијуму IV који су примали исти режим гемцитабина и цисплатина. Тиме се смањује хетерогеност терапије и омогућава јасна експериментална поставка, али се резултати не генерализују на друге болести и терапије.

Практични задатак је да се на основу података доступних пре терапијског исхода процени да ли ће пацијент припадати responder или non-responder класи. Позитивну класу чине потпун и делимичан одговор, а негативну стабилна и прогресивна болест. Записи без процењивог исхода нису произвољно придружени ниједној класи. Посебна пажња посвећена је спречавању цурења података: каснији лабораторијски резултати, број примљених циклуса, нежељени догађаји, време до прогресије и саме процене одговора не користе се као улази.

Циљ рада је развој репродуктивног информатичког система који обухвата анализу структуре података, формирање моделске кохорте, експлоративну анализу, претпроцесирање, поређење логистичке регресије, Elastic Net логистичке регресије, Random Forest, SVM и XGBoost модела, процену дискриминације и калибрације, SHAP интерпретацију и имплементацију веб-прототипа. Истраживачко питање гласи: да ли изабране baseline карактеристике у доступном скупу садрже довољно стабилан сигнал за предикцију вероватноће одговора код новог пацијента? Одговор се заснива на унакрсној валидацији тренинг скупа и једнократној евалуацији на издвојеном тест скупу.

Допринос рада је пре свега софтверско-методолошки. Развијен је проверљив ток од изворних SAS табела до серијализованог pipeline-а и веб-апликације; документовани су атрибути, подела података, хиперпараметри и моделски артефакти; приказан је и негативан експериментални резултат без прикривања неизвесности. Такав приступ је применљив и на друге скупове за предикцију терапијског исхода, уз нову доменску дефиницију кохорте, предиктора и циљне променљиве.

2. ПРОБЛЕМ ПРЕДИКЦИЈЕ ОДГОВОРА И СРОДНИ РАДОВИ

2.1. Предиктивни модели као информатички системи

Предиктивни модел није само обучени алгоритам. Комплетан систем обухвата извор података, правила издвајања примера, шему атрибута, претпроцесирање, научене параметре, интерфејс за унос и начин приказивања резултата. Грешка у било којој од ових компоненти може поништити формално исправан рад класификатора. Из угла информатике, главни задатак је зато пројектовање доследног и проверљивог тока података, а не само позив библиотечке методе `fit`.

Улазни подаци за предикцију одговора могу бити структурирани клинички атрибути, лабораторијске вредности, геномски и транскриптомски профили, медицинске слике или слободан текст. Различити модалитети захтевају различите поступке обраде и количину података. Табеларни клинички подаци омогућавају примену класичних алгоритама и лакше тумачење улаза, али често садрже недостајуће вредности, неуједначене категорије и ограничен број пацијената. Геномски и сликовни подаци носе више димензија, али повећавају сложеност, ризик overfitting-а и захтеве за независном провером.

Важно је разликовати прогнозу и предикцију терапијског ефекта. Прогностички модел процењује будући исход независно од конкретне интервенције, док предиктивни модел у ужем смислу треба да покаже како се очекивани исход мења у зависности од избора терапије. Рад са једним терапијским режимом, као у овом пројекту, процењује вероватноћу одговора у конкретној третираној популацији, али не доказује да би исти пацијент имао бољи исход него уз алтернативну терапију. Зато апликација није систем за аутоматски избор лека.

2.2. Заједнички методолошки изазови

Први изазов је дефиниција циљне променљиве. Исход мора бити мерљив, клинички и временски јасно одређен и доступан за довољан број примера. Спајање различитих исхода у једну класу олакшава моделирање, али губи део информације. У овом раду су CR и PR спојени у responder, а SD и PD у non-responder класу, док су непроцењиви исходи искључени.

Други изазов је ограничена величина узорка у односу на број могућих атрибута и конфигурација. Велики простор хиперпараметара може прилагодити модел случајној структури fold-ова. Зато се сложеност мора контролисати, а резултат приказати са мером варијабилности или интервалом поверења. Трећи изазов је цурење података, нарочито када табеле садрже догађаје настале после почетка терапије. Pipeline спречава цурење током импутације и скалирања, али не може сам препознати семантички недозвољен атрибут; то захтева анализу документације и времена настанка.

Четврти изазов је преносивост. Модел може научити специфичности једне студије, центра, популације или начина мерења. Интерна train/test подела процењује понашање на новим пацијентима из истог извора, али није екстерна валидација. Пети изазов је интерпретација вероватноће. Добра дискриминација не гарантује калибрацију, а праг 0,5 не мора одговарати практичној цени лажно позитивних и лажно негативних одлука.

2.3. Позиционирање овог рада

Овај рад не покушава да реплицира системе засноване на великим геномским или сликовним скуповима. Фокус је на класичном supervised-learning проблему са структурираним baseline подацима и ограниченим узорком. Та поставка је погодна за завршни рад из информатике и рачунарства јер омогућава да се обради цео lifecycle: профилисање табела, формирање кохорте, верзионисани експеримент, поређење алгоритама, серијализација, API и кориснички интерфејс.

SQUIRE није изабран зато што предложени поступак важи само за један тип карцинома, већ зато што је то био доступан, документован и довољно структуриран скуп са јасним терапијским крацима и категоријама одговора. Исти програмски образац може се применити на други скуп тек након нове провере јединица, временског прозора, значења исхода и дозвољених предиктора. Пренос кода без те доменске провере био би технички могућ, али методолошки неисправан.

Рад се од сродних истраживања разликује по томе што не тврди клиничку употребљивост када је евалуациони учинак слаб. Главни резултат је репродуктивна имплементација и критичка процена граница доступних података. Веб-апликација служи као демонстрација начина deployment-а истог pipeline-а, а не као медицинско средство или доказ да модел треба користити у доношењу одлука.

3. ОСНОВЕ МАШИНСКОГ УЧЕЊА И ПРЕДИКТИВНОГ МОДЕЛОВАЊА

3.1. Надгледано учење и класификација

Машинско учење обухвата поступке којима се на основу података процењује функција за предикцију или опис образаца. Код надгледаног учења сваки пример у тренинг подацима садржи улазне атрибуте и познату циљну вредност. Класификација је задатак у којем је циљ дискретна категорија. У овом раду позитивна класа означава објективни одговор на терапију, док негативна класа означава стабилну или прогресивну болест.

Модел не учи медицинску узрочност. Он процењује статистичку везу између посматраних карактеристика и исхода у расположивом узорку. Висока предиктивна способност не би сама по себи доказала да одређена карактеристика узрокује одговор, а ниска способност не доказује одсуство било какве биолошке повезаности. Ово разграничење је нарочито важно када је број пацијената ограничен, а доступни предиктори представљају само део клиничке слике.

3.2. Тренинг, тест и унакрсна валидација

Подаци су подељени на тренинг и тест скуп. Тренинг скуп служи за процену параметара и избор хиперпараметара, док тест скуп симулира до тада невиђене примере. Ако би тест подаци утицали на избор варијабли, импутацију, скалирање или хиперпараметре, коначна процена била би оптимистички пристрасна.

Због релативно малог узорка, унутар тренинг скупа примењена је петострука стратификована унакрсна валидација. У свакој итерацији четири дела служе за обуку, а преостали за валидацију. Стратификација приближно чува однос класа. Просек резултата смањује зависност од једне случајне валидационе поделе, али не уклања неизвесност нити замењује екстерну валидацију.

3.3. Overfitting, underfitting и цурење података

Прекомерно прилагођавање (*overfitting*) настаје када модел научи специфичности и шум тренинг узорка, па његов учинак опада на новим подацима. Недовољно прилагођавање (*underfitting*) јавља се када модел нема капацитет да представи релевантан образац. Разлика између веома високог учинка на тренинг подацима и слабог резултата у валидацији или тесту типичан је сигнал прекомерног прилагођавања.

Цурење података је посебан проблем: модел током обуке добија информацију која у стварном тренутку предикције није доступна или посредно открива исход. У здравственим подацима извор цурења може бити временски однос између предиктора и исхода, начин дефинисања етикете или глобално претпроцесирање пре поделе. Зато су целе домене ADRESP, ADTTE, ADEXSUM и ADAE искључене из предиктора. Из ADLB и ADVS узете су само експлицитно baseline вредности означене са `ABLFL=Y`. Импутација, кодирање и скалирање налазе се у pipeline-у и процењују се само на одговарајућем тренинг делу [8].

3.4. Недостајуће вредности и кодирање

Недостајућа вредност не значи увек исто: мерење можда није обављено, није забележено, није применљиво или је уклоњено током деидентификације. У овом раду нумеричке вредности замењене су медијаном из тренинг података, уз индикатор недостатка. Медијана је отпорнија на екстремне вредности од аритметичке средине. Категоријске вредности допуњене су најчешћом категоријом у тренинг делу, а затим претворене One-Hot поступком. Непознате категорије у новим подацима не доводе до грешке, али нису произвољно мапиране на познату категорију.

Нумерички атрибути су стандардизовани одузимањем тренинг средине и дељењем тренинг стандардном девијацијом. Ово је посебно важно за логистичку регресију и SVM, јер се атрибути налазе на различитим скалама. Код модела стабала скалирање по правилу није неопходно, али јединствена модуларна процедура поједностављује репродукцију и не нарушава резултат.

3.5. Неуравнотеженост класа

Када су класе различите величине, алгоритам током обуке види више примера већинске класе. У моделској кохорти non-responder класа чини 66,88%, а responder 33,12%. Модел који увек враћа већинску класу имао би accuracy приближно 0,669, иако не би препознао ниједног responder-a. Ова референтна вредност омогућава правилно тумачење SVM accuracy резултата од 0,667.

Постоје три широке групе приступа: промена расподеле узорка, промена функције грешке и промена прага. Oversampling понавља или синтетички генерише мањинске примере, undersampling одбацује део већинских, а class weighting додељује различиту цену грешкама. Промена прага не мења обучени модел, већ начин претварања вероватноће у класу.

SMOTE није аутоматски примењен. Синтетички пацијент настао интерполацијом може имати математички валидан, али клинички необичан профил, нарочито после One-Hot кодирања и у присуству недостајућих вредности. Oversampling такође мора бити извршен само унутар тренинг fold-a; примена пре cross-validation поделе довела би сродне синтетичке примере у тренинг и валидацију.

У овом раду class weighting је испитан тамо где га алгоритам природно подржава, али је изабрана комбинација зависила од CV ROC AUC. Поред ROC AUC извештавани су precision, recall, F1 и PR AUC. Тако модел не може бити проглашен успешним само зато што добро препознаје бројнију негативну класу.

3.6. Калибрација вероватноће

Дискриминација и калибрација су различита својства. ROC AUC мери способност рангирања, док калибрација испитује да ли предвиђене вероватноће одговарају посматраним учесталостима. Ако група пацијената добије процену око 0,7, добро калибрисан модел би у сличној популацији требало да има приближно 70% позитивних исхода у тој групи.

Логистичка регресија често даје употребљивије вероватноће од некалибрисаних margin скорова, али добра калибрација није гарантована. У овом раду калибрација се процењује Brier score метриком, ECE вредношћу и calibration кривом са пет квантилних интервала. Мање вредности Brier score и ECE означавају мање одступање предвиђених

вероватноћа од посматраних исхода, уз напомену да тест скуп од 96 пацијената ограничава прецизност процене.

SVM је обухваћен CalibratedClassifierCV поступком са sigmoid калибрацијом, при чему се основни SVM подешава унутар тренинг података. Random Forest вероватноћу формира агрегирањем стабала, а XGBoost логистичком трансформацијом ансамбл скора. Сви модели се затим процењују истим метрикама на независном тест скупу.

Апликација приказује процењену вероватноћу са једном децималом, али то није мерна резолуција нити интервал поверења за појединца. Приказ `54,7%` не значи да је систем познат до десетог дела процента. То је нумерички излаз pipeline-а и мора се читати уз слабу дискриминацију и непостојање екстерне валидације.

3.7. Избор прага и цена грешке

Подразумевани праг 0,5 претвара вероватноћу у позитивну класу када је она бар једнака половини. Тај праг није универзално оптималан. Ако је важније препознати што више responder-а, праг се може снизити и повећати recall, али ће порасти број лажно позитивних. Ако су лажно позитивни исходи скупљи, праг се може повећати.

Оптимизација прага захтева формалну функцију трошка или клиничку дефиницију користи. У супротном би избор прага на тест скупу био још један облик прилагођавања тесту. У раду је праг 0,5 задржан као унапред разумљива референтна тачка, а ROC и PR криве приказују понашање кроз различите прагове.

Матрица конфузије мора се тумачити уз конкретан праг. SVM је при прагу 0,5 све тест примере сврстао у non-responder класу, па има specificity 1 и sensitivity 0, иако је accuracy 0,667. Elastic Net је препознао 17 од 32 responder-а и имао sensitivity 0,531, уз specificity 0,516. Овај пример показује зашто accuracy мора бити допуњена sensitivity, specificity, precision, F1 и balanced accuracy метрикама.

За будући decision-support систем праг би морао да буде одређен на development подацима, затим закључан и проверен у независној кохорти. Поред статистичких метрика потребна је decision-curve анализа или друга формална процена нето користи. Без тога апликација не сме да представља бинарну ознаку као терапијску препоруку.

3.8. Хиперпараметри и контролисана претрага

Параметри модела уче се из података, док хиперпараметре задаје поступак развоја. Примери су јачина регуларизације `C`, дубина стабла, број стабала, `gamma`, learning rate и минималан број примера у листу. Већи простор претраге повећава шансу да се пронађе добра конфигурација, али и шансу да се валидациони шум прогласи за побољшање.

GridSearchCV систематски испитује унапред задате комбинације. За сваку комбинацију извршава се пет fit операција, по једна за сваки fold. Ако модел има 12 комбинација, то значи најмање 60 обука, а затим још једну обуку најбоље комбинације на целом тренинг скупу. Укупна цена зависи од сложености алгоритма и димензије трансформисане матрице.

Претрага у овом раду намерно је мала. Њен циљ није исцрпно освајање сваке хиљадитинке ROC AUC, већ фер поређење разумних конфигурација. Сваки pipeline садржи и preprocessing, па се медијане, категорије и scaler поново процењују унутар

сваког fold-а. Ово је рачунски скупље од једнократне глобалне трансформације, али методолошки неопходно.

Избор логистичке регресије применом правила једне стандардне грешке додатно ограничава оптимизам. Ако су модели статистички блиски у валидацији, сложенији се не бира само због незнатно већег просека. Ово правило је нарочито оправдано када стандардна девијација fold-ова вишеструко премашује разлику средњих резултата.

4. КОРИШЋЕНИ МОДЕЛИ И МЕТРИКЕ

4.1. Logistic Regression

Логистичка регресија процењује вероватноћу позитивне класе применом логистичке функције на линеарну комбинацију улазних карактеристика. Иако назив садржи реч регресија, модел се широко користи за бинарну класификацију. Коефицијенти омогућавају увид у смер везе између трансформисаног атрибута и прогнозе, под условом да се не тумаче као узрочни ефекти.

Предности су једноставност, брза обука и релативна интерпретабилност. Ограничење је претпоставка линеарне везе на log-odds скали, осим ако се интеракције и нелинеарне трансформације експлицитно додају. Регуларизација контролише величину коефицијената и смањује ризик од прекомерног прилагођавања.

4.2. Elastic Net Logistic Regression

Elastic Net логистичка регресија проширује стандардни модел комбиновањем L1 и L2 казне. L1 компонента може поставити део коефицијената на нулу и тиме обавити уграђену селекцију трансформисаних атрибута, док L2 компонента стабилизује коефицијенте корелисаних карактеристика. Однос две компоненте контролише параметар l1_ratio, а укупну јачину регуларизације параметар C [11].

Ова комбинација је погодна за скуп са 477 пацијената и 18 почетних атрибута, јер One-Hot кодирање и индикатори недостајућих вредности повећавају број трансформисаних колона. Elastic Net ограничава варијансу без потпуног одбацивања група повезаних предиктора. У раду је коришћен SAGA решавач, а C, l1_ratio и class_weight бирани су искључиво унутар унакрсне валидације тренинг скупа.

4.3. Random Forest

Random Forest је ансамбл стабала одлучивања. Свако стабло обучава се на bootstrap узорку, а при подели чвора разматра се случајан подскуп карактеристика. Коначна одлука настаје агрегирањем предикција стабала. Овај приступ може да представи нелинеарне односе и интеракције без њиховог ручног задавања [3].

Модел је отпоран у многим табеларним задацима, али на малом узорку са великим бројем кодираних карактеристика може научити нестабилне поделе. Важности атрибута такође не треба изједначавати са клиничким значајем. У овом истраживању ограничавани су дубина стабала, минималан број примера у листу и број разматраних карактеристика.

4.4. Support Vector Machine

SVM тражи границу која раздваја класе са што већом маргином. Kernel функција омогућава нелинеарно раздвајање без експлицитног конструисања свих трансформисаних димензија. Параметар `C` регулише компромис између ширине маргине и грешака на тренинг подацима, док `gamma` код RBF kernel-а утиче на локалност границе [4].

SVM може бити ефикасан у просторима са много атрибута, али је осетљив на скалу и избор хиперпараметара. Вероватноће захтевају додатну калибрацију. У малом и умерено неуравнотеженом узорку сложена граница може лако постати нестабилна.

4.5. XGBoost

XGBoost гради стабла секвенцијално тако да свако наредно стабло коригује грешке ансамбла. Циљна функција садржи меру грешке и члан регуларизације, а имплементација је оптимизована за ефикасан рад са табеларним подацима. Модел може да представи сложене интеракције, али има више хиперпараметара и велики капацитет [5].

У медицинском скупу од неколико стотина пацијената та флексибилност није аутоматска предност. Дубока стабла, велики број итерација или превисока стопа учења могу произвести скоро савршено уклапање тренинг података без генерализације. Зато је коришћен мали, унапред ограничен простор претраге.

4.6. Матрица конфузије, дискриминација и калибрација

Матрица конфузије садржи тачно позитивне (TP), лажно позитивне (FP), тачно негативне (TN) и лажно негативне (FN) исходе. Accuracy је удео свих тачних класификација. Precision, TP/(TP+FP), показује колики део пацијената означених као responder заиста припада позитивној класи. Recall, TP/(TP+FN), показује колики део стварних responder-а је препознат. F1 је хармонијска средина precision и recall.

Када је негативна класа чешћа, модел може остварити релативно високу accuracy вредност честим предвиђањем негативне класе. Зато accuracy није довољна. ROC крива приказује однос осетљивости и стопе лажно позитивних кроз све прагове, а ROC AUC вероватноћу да насумично изабран позитиван пример добије виши скор од негативног. Вредност 0,5 одговара рангирању без дискриминативне информације.

Precision–Recall крива је посебно информативна када су класе неуравнотежене, јер непосредно приказује компромис у препознавању позитивне класе. У овом раду приказана је и PR AUC, иако је унапред изабрана метрика за подешавање модела ROC AUC. За тест ROC AUC израчунати су 95% bootstrap интервали поверења, чиме је приказана неизвесност услед ограничене величине тест скупа [9].

5. СОФТВЕРСКА ИМПЛЕМЕНТАЦИЈА СИСТЕМА МАШИНСКОГ УЧЕЊА

5.1. Организација аналитичког решења

Решење је реализовано као низ независних, али повезаних програмских корака. Ова подела је важна јер раздваја припрему података, експлораторну анализу, обуку модела, тумачење резултата и покретање веб-апликације. Уместо једне велике скрипте чије је понашање тешко контролисати, свака фаза има јасан улаз, излаз и одговорност. На тај начин се грешка може локализовати, а појединa фаза поновити без поновног извршавања целог поступка.

Скрипта profile_sas.ps1 прегледа структуру изворних SAS табела, док export_dictionary.ps1 формира речник колона. Након тога build_ml_cohort.ps1 издваја пацијенте контролне гране, формира циљну променљиву и спаја baseline карактеристике у један запис по испитанику. Скрипта eda.py генерише статистичке прегледе и графиконе, train_models.py спроводи поделу, претпроцесирање, унакрсну валидацију и евалуацију пет модела, а interpret_and_finalize.py израчунава интервале поверења, SHAP вредности и припрема deployment модел. Веб-слој у app/main.py учитава готов артефакт и не обучава модел током корисничког захтева.

Оваква архитектура раздваја offline и online део. Offline део је рачунски захтевнији и обухвата све поступке у којима се уче параметри. Online део прима један профил пацијента, примењује већ научене трансформације и враћа процену. То спречава да се скалирање, импутација или избор категорија случајно поново прилагођавају подацима унетим кроз апликацију.

5.2. Дефинисање улаза и контролисан избор атрибута

Улаз модела није формиран аутоматским преузимањем свих доступних колона. Изворне табеле садрже идентификаторе, описе исхода, податке настале после почетка терапије и техничке колоне које не смеју постати предиктори. Због тога је листа атрибута експлицитно дефинисана у коду. Она садржи 14 нумеричких и четири категоријска атрибута, укупно 18 улаза.

Листинг 1. Извод из програмског кода

```
NUMERIC_FEATURES = [
    "AGE", "ECOGBL", "BMIBL", "ALB", "HGB", "NEUT", "LYM",
    "WBC", "PLAT", "CREAT", "LDH", "SODIUM", "ALT", "AST",
]
CATEGORICAL_FEATURES = ["SEX", "ARACE", "SMKB", "HISTOLG"]
FEATURES = NUMERIC_FEATURES + CATEGORICAL_FEATURES
```

Експлицитна листа има више предности. Прво, код јасно документује моделски улаз. Друго, промена структуре неке изворне табеле не може неприметно додати нову колону у модел. Треће, идентификатор `USUBJID` остаје доступан само за спајање и audit поделе, али се не прослеђује класификатору. Циљна променљива `RESPONSE` такође је издвојена од матрице предиктора.

За сваки изабрани лабораторијски параметар коришћена је baseline вредност у стандардној јединици. То је суштинска контрола спречавања цурења података: вредности настале после терапије могле би посредно открити исход. Фиксирана листа атрибута зато није само програмска погодност, већ део експерименталног дизајна.

5.3. Pipeline за претпроцесирање

Нумеричке и категоријске колоне захтевају различите поступке. Нумеричке вредности пролазе кроз импутацију медијаном и стандардизацију. Опција `add_indicator=True` додаје бинарни индикатор за колоне у којима постоје недостајуће вредности, па модел може разликовати стварно измерену вредност од вредности замењене медијаном. Стандардизација је нарочито важна за логистичку регресију и SVM јер се њихова оптимизација ослања на упоредиве скале улаза.

Категоријске вредности најпре се допуњавају најчешћом категоријом, а затим One-Hot кодирају. Параметар `handle_unknown="ignore"` омогућава да трансформација не прекине рад ако се током примене појави категорија која није имала сопствену колону током обуке. Параметар `min_frequency=5` групише ретке категорије и ограничава непотребно повећање димензионалности.

Листинг 2. Извод из програмског кода

```
def make_preprocessor():
    numeric = Pipeline([
        ("imputer", SimpleImputer(strategy="median", add_indicator=True)),
        ("scaler", StandardScaler()),
    ])
    categorical = Pipeline([
        ("imputer", SimpleImputer(strategy="most_frequent")),
        ("onehot", OneHotEncoder(handle_unknown="ignore",
                                 min_frequency=5)),
    ])
    return ColumnTransformer([
        ("numeric", numeric, NUMERIC_FEATURES),
        ("categorical", categorical, CATEGORICAL_FEATURES),
    ])
```

`ColumnTransformer` спаја обе гране у јединствену трансформисану матрицу. Претпроцесор и класификатор се затим смештају у исти scikit-learn `Pipeline` . Ово је важније од ручног извршавања корака: при сваком fold-у унакрсне валидације медијане, средине, стандардне девијације и категорије уче се искључиво на тренинг делу тог fold-а. Тако се спречава да информација из валидационог дела утиче на трансформације.

5.4. Подела података и репродуктивност експеримента

Моделска кохорта од 477 пацијената подељена је у односу 80:20. Тренинг скуп садржи 381, а независни тест скуп 96 пацијената. Параметар `stratify=y` приближно чува однос responder и non-responder класе у оба дела, што је важно код неуравнотежене циљне променљиве. Параметар `random_state=42` фиксира случајну поделу.

Листинг 3. Извод из програмског кода

```
X_train, X_test, y_train, y_test, id_train, id_test = train_test_split(
    X, y, ids, test_size=0.20, stratify=y, random_state=42
)
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Идентификатори обе поделе чувају се у датотекама `train_ids.csv` и `test_ids.csv`. Оне представљају audit траг: могуће је тачно утврдити који је пацијент учествовао у оптимизацији, а који само у завршној евалуацији. Тест скуп се не користи за избор алгоритма или хиперпараметара.

Унутар тренинг скупа примењена је петострука стратификована унакрсна валидација. Свака конфигурација се обучава пет пута, тако да сваки fold једном служи за валидацију. Средња ROC AUC вредност представља процену рангирајуће способности, а стандардна девијација показује осетљивост на конкретан састав fold-а. Код малог скупа велика варијација између fold-ова је подједнако важна као средња вредност.

5.5. Јединствен оквир за пет модела

Логистичка регресија, Elastic Net логистичка регресија, Random Forest, SVM и XGBoost обучавани су у истом методолошком оквиру. За сваки алгоритам формиран је pipeline са истим претпроцесором, истом поделом и истим fold-овима. На тај начин разлика у резултату превасходно потиче од модела и његових хиперпараметара, а не од другачије припреме података.

Речник models повезује назив алгоритма, објекат класификатора и простор параметара. Код стандардне логистичке регресије испитани су C и тежине класа. Elastic Net варијанта користи SAGA решавач и заједничку L1/L2 регуларизацију; подешавани су C, l1_ratio и class_weight. За Random Forest провераване су дубина стабала, минималан број примера у листу и тежине класа. SVM је калибрисан sigmoid поступком, а подешавани су C, gamma и тежине класа. За XGBoost контролисани су број и дубина стабала, learning rate, subsampling и избор колона.

Листинг 4. Извод из програмског кода

```
for name, (estimator, grid) in models.items():
    pipeline = Pipeline([
        ("preprocess", make_preprocessor()),
        ("model", estimator),
    ])
    search = GridSearchCV(
        pipeline, grid, scoring="roc_auc", cv=cv,
        n_jobs=-1, return_train_score=True, refit=True
    )
    search.fit(X_train, y_train)
```

`GridSearchCV` систематски испитује задате комбинације. Пошто је претпроцесор део pipeline-а, свака комбинација садржи и потпуно независно fit-овање трансформација. Параметар `refit=True` након претраге поново обучава најбољу конфигурацију на целом тренинг скупу. Чувају се и тренинг и валидационе вредности, што омогућава препознавање overfitting-а.

Претрага није неограничена. Код 381 тренинг пацијента велики простор хиперпараметара повећао би ризик да се случајно пронађе конфигурација прилагођена конкретним fold-овима. Зато су коришћене унапред дефинисане, умерене мреже параметара, довољне да се упореде разумне варијанте без прикривеног исцрпљивања валидационог скупа.

5.6. Израчунавање метрика и чување резултата

После избора најбоље конфигурације сваког алгоритма, на независном тест скупу израчунавају се вероватноће позитивне класе. Класа се добија поређењем вероватноће са прагом 0,5. Из матрице конфузије добијају се TN, FP, FN и TP, а затим accuracy, sensitivity/recall, specificity, precision, F1 и balanced accuracy. ROC AUC и PR AUC користе континуалне вероватноће. Brier score мери средњу квадратну грешку вероватноће, ECE просечно апсолутно одступање у пет квантилних интервала, а

calibration крива визуелно пореди предвиђене вероватноће са посматраним учесталостима.

Све вредности се уписују у `model_comparison.csv`, а појединачне вероватноће и класе у `test_predictions.csv`. За сваку претрагу чува се и комплетан `cv_results_` излаз. Ово омогућава да се накнадно провери свака испитана конфигурација, а не само победнички резултат.

Тест ROC AUC додатно је праћен bootstrap интервалом поверења. У 3.000 понављања из тест скупа се узоркује 96 записа са понављањем; понављања која не садрже обе класе се прескачу. Границе 2,5. и 97,5. перцентила формирају 95% интервал. Широки интервали у овом раду показују да разлике између модела нису довољно стабилне за снажан закључак о њиховој супериорности.

Калибрациона крива формира пет група једнаке приближне величине према предвиђеној вероватноћи. За сваку групу пореде се средња процењена вероватноћа и стварни удео responder-a. Brier score и ECE допуњују графикон једним бројем, али се тумаче заједно са величином тест скупа и распоном издатих вероватноћа.

5.7. Избор финалног модела без увида у тест резултат

Највећу средњу CV ROC AUC вредност остварила је Elastic Net логистичка регресија, 0,540. Стандардна логистичка регресија са 0,536 налазила се унутар једне стандардне грешке. Elastic Net је задржан као финални модел јер је имао највиши CV просек, истовремено примењује L1 и L2 регуларизацију и може да смањи утицај нестабилних или сувишних трансформисаних атрибута.

Примењено је правило једне стандардне грешке као контрола претераног ослањања на мале разлике у CV резултатима. Модели унутар тог опсега сматрају се практично упоредивим, а предност има парсимоничнији регуларизовани модел. Редослед преференције постављен је на Elastic Net логистичку регресију, стандардну логистичку регресију, SVM, Random Forest и XGBoost.

Листинг 5. Извод из програмског кода

```
best_row = results_df.iloc[0]
best_se = best_row["CV_ROC_AUC_std"] / np.sqrt(cv.get_n_splits())
eligible = set(results_df.loc[
    results_df["CV_ROC_AUC_mean"] >=
    best_row["CV_ROC_AUC_mean"] - best_se, "Model"
])
preference = [
    "Elastic Net Logistic Regression", "Logistic Regression",
    "SVM", "Random Forest", "XGBoost",
]
best_name = next(name for name in preference if name in eligible)
```

Овај избор се спроводи без читања тест ROC AUC вредности. Тест скуп остаје независна провера већ донете одлуке. Elastic Net логистичка регресија изабрана је због највишег CV просека, регуларизације прилагођене малом узорку и могућности SHAP разлагања линеарног скора. Избор не значи да је модел клинички довољно добар; он одређује најпогоднији демонстрациони модел у оквиру спроведеног експеримента.

5.8. Серијализација, deployment модел и метаподаци

Изабрани pipeline се серијализује библиотеком `joblib`. Артефакт `best_model.joblib` представља модел коришћен у евалуацији: обучен је на 381

пацијенту и његов учинак је измерен на фиксних 96 тест пацијената. Након завршетка евалуације, иста архитектура и већ изабрани хиперпараметри клонирају се и обучавају на свих 477 пацијената. Тај артефакт се чува као `deployment_model.joblib` и користи га веб-прототип.

Раздвајање ова два артефакта спречава методолошку забуну. Deployment модел има приступ већем броју примера, али његов учинак се не приказује као нова независна тест метрика. У апликацији се и даље наводе резултати модела евалуираног на издвојеном тест скупу.

Поред бинарног артефакта, чува се `model_metadata.json` са називом модела, правилом избора, случајним семеном, бројем тренинг и тест примера, листама атрибута, позитивном класом и прагом. `input_schema.json` садржи јединице, медијане, развојне минимуме и максимуме и дозвољене категорије. На овај начин апликација не зависи од ручно преписаних вредности и може да прикаже структуру улаза која одговара обученом моделу.

5.9. SHAP анализа и локално објашњење

За финални Elastic Net модел примењен је SHAP LinearExplainer над трансформисаним тест подацима. SHAP вредност представља адитивни допринос атрибута одступању модела од очекиваног излаза. За линеарни логистички модел доприноси су изражени на log-odds скали, што омогућава математички доследно глобално и локално објашњење.

Глобални приказ рангира атрибуте према средњој апсолутној SHAP вредности, док beeswarm графикон истовремено приказује смер, величину и расподелу доприноса. Waterfall приказ показује како појединачни атрибути померају једну процену од очекиване вредности ка коначном резултату. SHAP описује понашање модела у датом узорку и не доказује узрочни или клинички ефекат.

5.10. Рачунарска сложеност и практичне разлике модела

Поређење класификатора не треба ограничити само на једну метрику. Алгоритми се разликују и по времену обуке, меморијским захтевима, брзини предикције и могућности тумачења. У овом пројекту скуп од 477 пацијената није довољно велики да би ресурси били критично ограничење, али анализа сложености показује како би се решење понашало при већем броју записа или чешћем поновном обучавању.

Логистичка регресија након претпроцесирања учи један коефицијент за сваку трансформисану колону и један слободни члан. Предикција се своди на скаларни производ вектора и коефицијената и примену логистичке функције. Време једне предикције расте приближно линеарно са бројем трансформисаних атрибута, а меморијски захтев одређен је релативно малим вектором коефицијената. Ова особина је погодна за веб-сервис који модел држи у меморији и обрађује појединачне захтеве.

SVM са нелинеарним RBF kernel-ом током предикције упоређује нови пример са support векторима наученим током обуке. Пошто основни SVM не производи директно калибрисане вероватноће, у имплементацији је обухваћен CalibratedClassifierCV поступком са sigmoid калибрацијом и ensemble=False. Овај додатни корак повећава сложеност обуке, али омогућава да се SVM процени истим Brier и calibration метрикама као остали модели.

Random Forest чува 400 стабала. Једна предикција пролази кроз свако стабло, а коначна вероватноћа добија се агрегирањем њихових излаза. Стабла се могу паралелно обучавати, али серијализовани артефакт обично је већи од линеарног модела. Ограничења `max_depth` и `min_samples_leaf` имају двоструку улогу: смањују overfitting и ограничавају величину структуре. Ипак, веома висок тренинг ROC AUC уз слаб валидациони резултат показује да је расположиви капацитет и даље био већи од стабилне информације у подацима.

XGBoost гради стабла секвенцијално, при чему свако наредно стабло коригује грешке претходног ансамбла. Параметри `learning_rate`, `n_estimators`, `max_depth`, `subsample` и `colsample_bytree` заједно контролишу капацитет. Велики број комбинација повећава и цену Grid Search поступка: свака конфигурација се обучава у пет fold-ова, па број fit операција брзо расте.

У конкретној имплементацији брзина inference-а није коришћена као пресудан критеријум јер је свих пет модела довољно брзо за једног локалног корисника. Важнији су били стабилност валидације, регуларизација, величина артефакта и интерпретабилност. Избор Elastic Net логистичке регресије има и софтверско-инжењерско оправдање: модел остаје линеаран, серијализује се у јединственом pipeline-у и омогућава проверљива локална и глобална објашњења.

За систем са већим оптерећењем било би потребно посебно мерити latency и throughput. Тест би требало да раздвоји време JSON валидације, конструисања DataFrame-а, претпроцесирања и методе `predict_proba`. Потребно је испитати cold start, паралелне захтеве, величину процеса у меморији и понашање при рестартовању. Постојећи рад не проглашава систем real-time решењем, јер за такав закључак мора постојати формално временско ограничење и доказ да је оно испуњено у најнеповољнијим условима.

6. СКУП ПОДАТАКА И ФОРМИРАЊЕ КОХОРТЕ

6.1. Студија SQUIRE

SQUIRE је била отворена, рандомизована студија фазе III спроведена у 184 центра у 26 земаља. Укупно 1.093 пацијента распоређена су на necitumumab са гемцитабином и цисплатином или на гемцитабин и цисплатин. Примарни циљ оригиналне студије односио се на поређење терапијских кракова. Циљ овог рада је другачији: унутар контролног крака испитује се предвидивост одговора на исту терапију [1].

Подаци су преузети из Project Data Sphere репозиторијума под DOI идентификатором 10.34949/05tc-jx78. Анализа је извршена над локално достављеним SAS ADaM табелама и пратећом документацијом: протоколом, анотираним CRF-ом и `define` документом. Све одлуке о значењу променљивих проверене су у овим изворима, а не само на основу кратког назива колоне [2].

6.2. Структура достављених табела

Достављено је девет `.sas7bdat` табела са укупно 405.320 редова и 1.233 колоне посматрано као збир колона по доменима. Табела ADSL садржи један запис по испитанику; остале табеле углавном садрже поновљена мерења или догађаје.

Табела 2. Структура достављених ADaM табела.

Табела	Број редова	Број колона	Основно значење
ADSL	549	172	карактеристике на нивоу испитаника
ADAE	6.544	156	нежељени догађаји
ADCM	21.163	142	истовремена терапија
ADEXSUM	42.198	114	изложеност терапији
ADLB	248.760	143	лабораторијска мерења
ADMH	4.460	117	медицинска историја
ADRESP	7.338	118	процене туморског одговора
ADTTE	13.725	137	исходи типа време-до-догађаја
ADVS	60.583	134	витални знаци

Иако ADSL има 549 редова, само 548 испитаника има ознаку `ITTFL=Y`, што се поклапа са величином контролног крака у оригиналној публикацији. Један запис није припадао ITT популацији. Безбедносну популацију чинио је 541 пацијент, док осам није примило терапију. Ова разлика показује зашто број редова у техничкој табели није увек једнак броју пацијената у конкретној аналитичкој популацији.

6.3. Дефинисање циљне променљиве

У ITT популацији расподела BESTRESP била је: CR 3, PR 155, SD 264, PD 55, *Not Applicable* 59 и *Unable to Evaluate* 12. Примарна моделска кохорта формирана је задржавањем CR, PR, SD и PD. Тако је добијено 477 пацијената: 158 responder-а (33,12%) и 319 non-responder-а (66,88%).

Однос класа приближно је 1:2. Ово јесте умерена неуравнотеженост, али није примењен SMOTE. Синтетичко генерисање клиничких профила у малом, мешовитом скупу могло би да уведе нереалне комбинације и додатну варијансу. Уместо тога, подела је стратификована, метрике су изабране тако да не зависе само од већинске класе, а `class_weight` је био део контролисаног простора претраге где га модел подржава.

6.4. Избор предиктора

Коначни скуп садржи 18 атрибута: 14 нумеричких и четири категоријска. Нумерички су старост, ECOG, индекс телесне масе, албумин, хемоглобин, неутрофили, лимфоцити, леукоцити, тромбоцити, креатинин, LDH, натријум, ALT и AST. Категоријски су пол, агрегирана раса, пушачки статус и хистолошка категорија. Сва лабораторијска мерења преузета су искључиво из записа са baseline заставицом.

Табела 3. Групе изабраних baseline предиктора и начин обраде.

Група	Атрибути	Разлог укључивања	Обрада
Демографија	AGE, SEX, ARACE	доступни пре терапије; основни опис пацијента	скалирање / One-Hot
Функционално стање	ECOGBL	baseline процена општег стања	медијана и скалирање
Телесна грађа	BMIBL	baseline нутритивни и општи показатељ	медијана и скалирање
Крвна слика	HGB, NEUT, LYM, WBC, PLAT	baseline хематолошки статус	медијана, индикатор недостатка, скалирање
Биохемија	ALB, CREAT, LDH, SODIUM, ALT, AST	функција органа и опште стање	медијана, индикатор недостатка, скалирање
Клиничка историја	SMKB, HISTOLG	пушење и потврђена хистологија	One-Hot

Идентификатори пацијената коришћени су само за спајање и поделу, не као предиктори. BESTRESP је искључиво target. Табеле ADRESP, ADTTE, ADEXSUM и ADAE садрже исход или информације настале после почетка терапије и нису коришћене. ADCM и ADMH нису аутоматски укључене, јер је за сваку ставку потребна временска провера и додатно кодирање. Ово је конзервативна одлука која смањује ризик од цурења и број димензија.

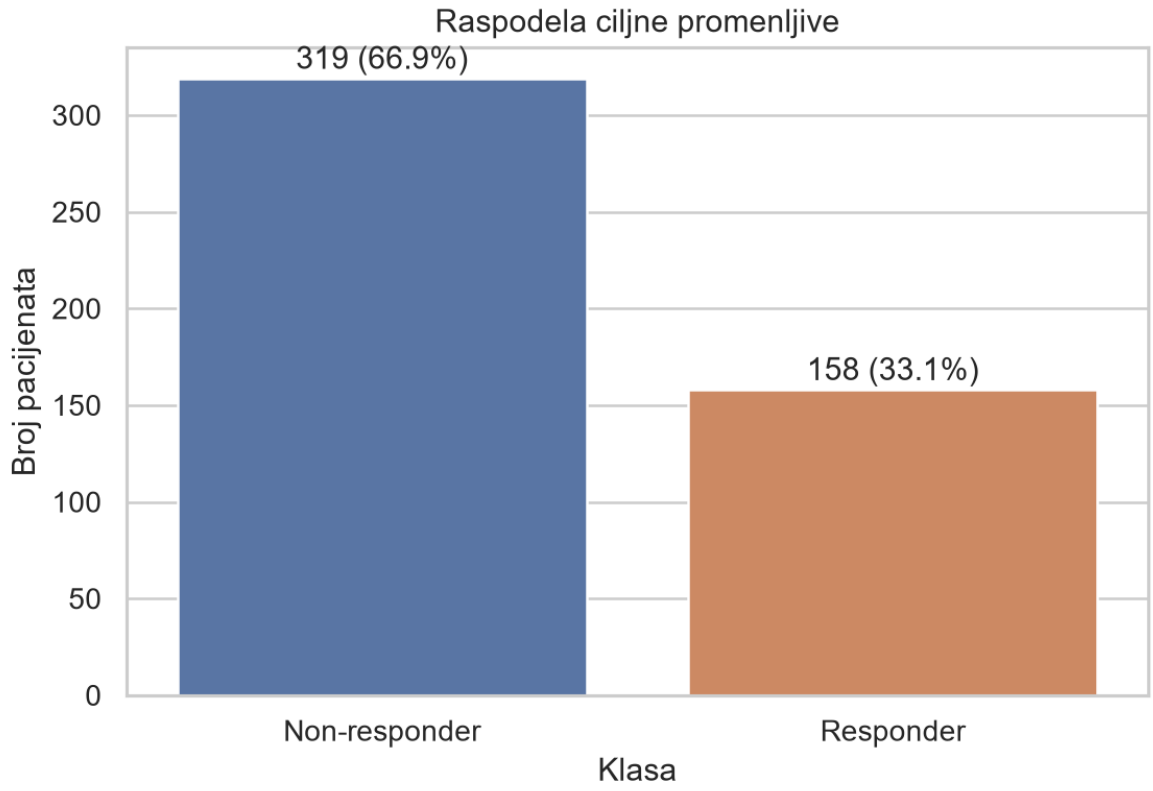
Посебна техничка провера била је неопходна у ADLB. Исте кратке шифре, на пример WBC, RBC, GLUC, PROT и BILI, могу постојати у различитим категоријама и јединицама. Зато су параметри истовремено филтрирани према категорији анализе и стандардној јединици.

7. ЕКСПЛОРАТИВНА АНАЛИЗА И ПРЕТПРОЦЕСИРАЊЕ

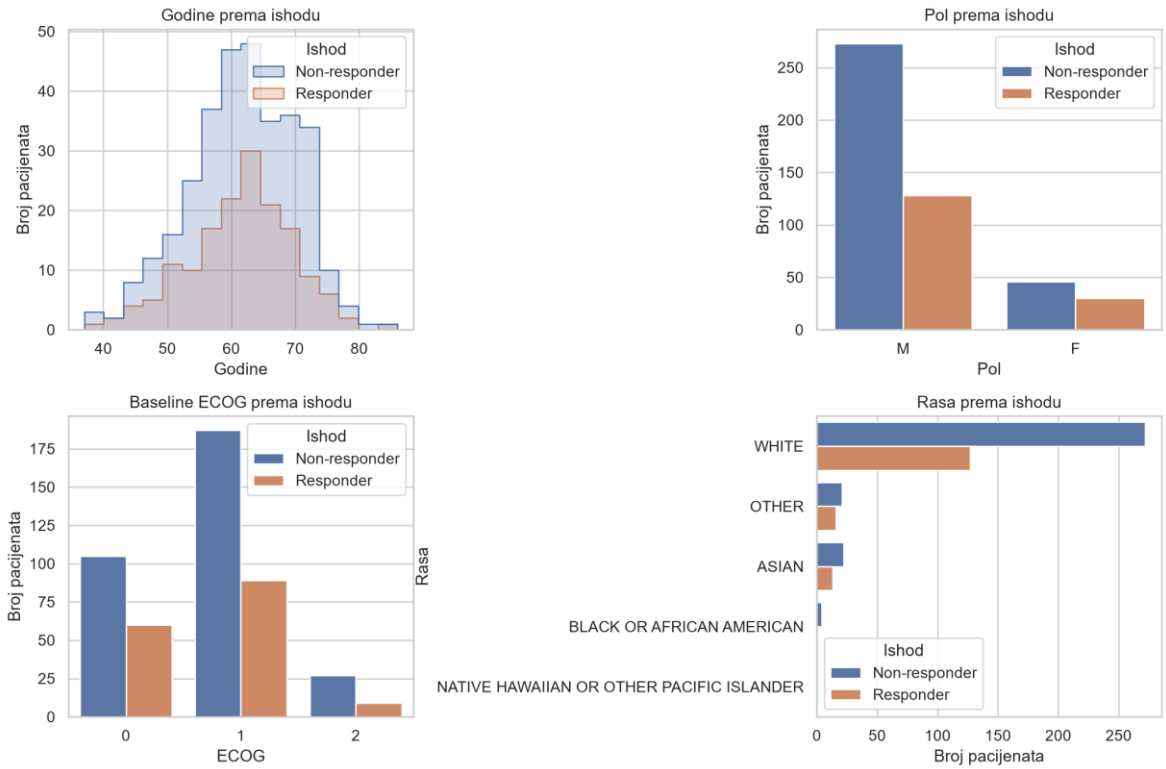
7.1. Опис моделске кохорте

Од 477 пацијената, 401 је био мушког (84,07%), а 76 женског пола. Раса је кодирана као WHITE код 399 пацијената (83,65%), ASIAN код 35, BLACK OR AFRICAN AMERICAN код пет, NATIVE HAWAIIAN OR OTHER PACIFIC ISLANDER код једног, док је 37 сврстано у агрегиране остале категорије. ECOG 0 имало је 165 пацијената, ECOG 1 њих 276, а ECOG 2 њих 36. Широка категорија пушачког статуса „Smoker (all others)" обухватила је 432 пацијента (90,57%).

Овакве расподеле имају две последице. Прво, модел располаже са мало примера за поједине мањинске категорије, па су процене њихових коефицијената нестабилне. Друго, резултати се не могу без провере пренети на популацију са другачијим полним, расним или пушачким саставом.



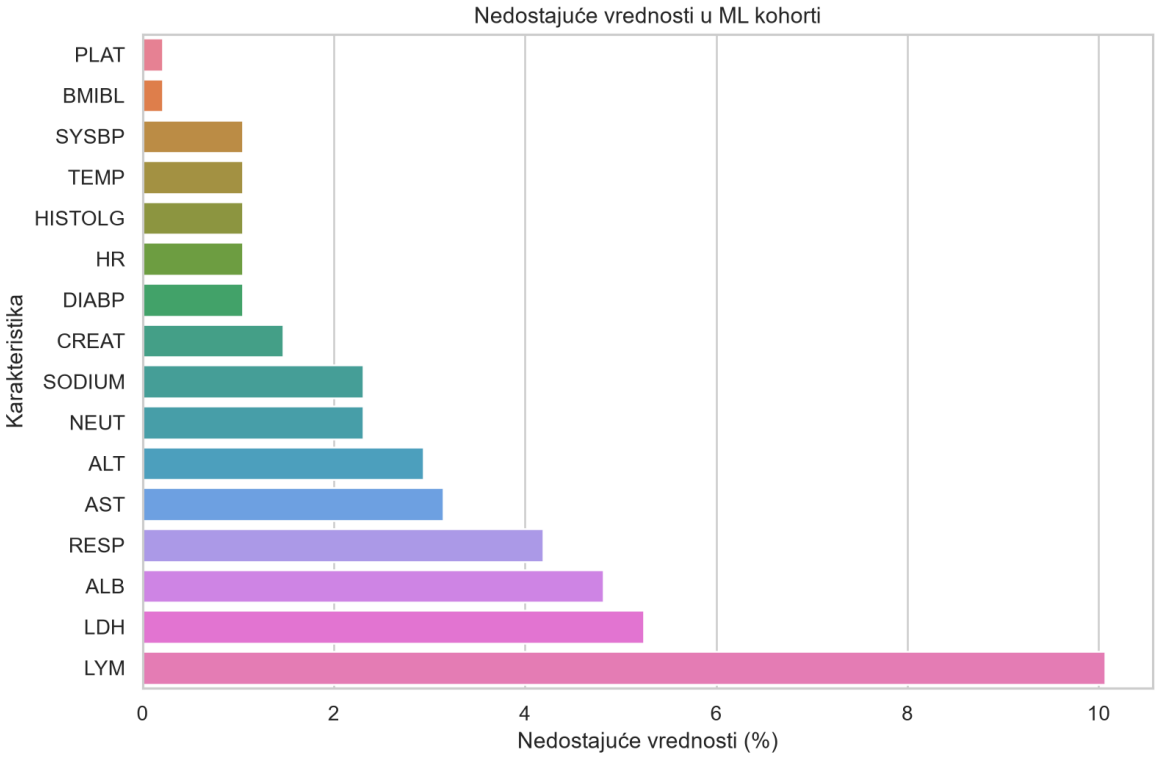
Слика 1. Расподела responder и non-responder класе у моделској кохорти.



Слика 2. Расподеле пола, расе и ECOG статуса.

7.2. Недостајуће вредности

Највећи удео недостајућих вредности међу изабраним атрибутима забележен је за лимфоците, 10,06%, затим LDH, 5,24%, и албумин, 4,82%. Код осталих изабраних лабораторијских карактеристика недостатак је углавном био мањи од 3,2%. Недостајуће вредности нису уклањане комплетним брисањем редова, јер би се смањио узорак и потенцијално променио састав кохорте.

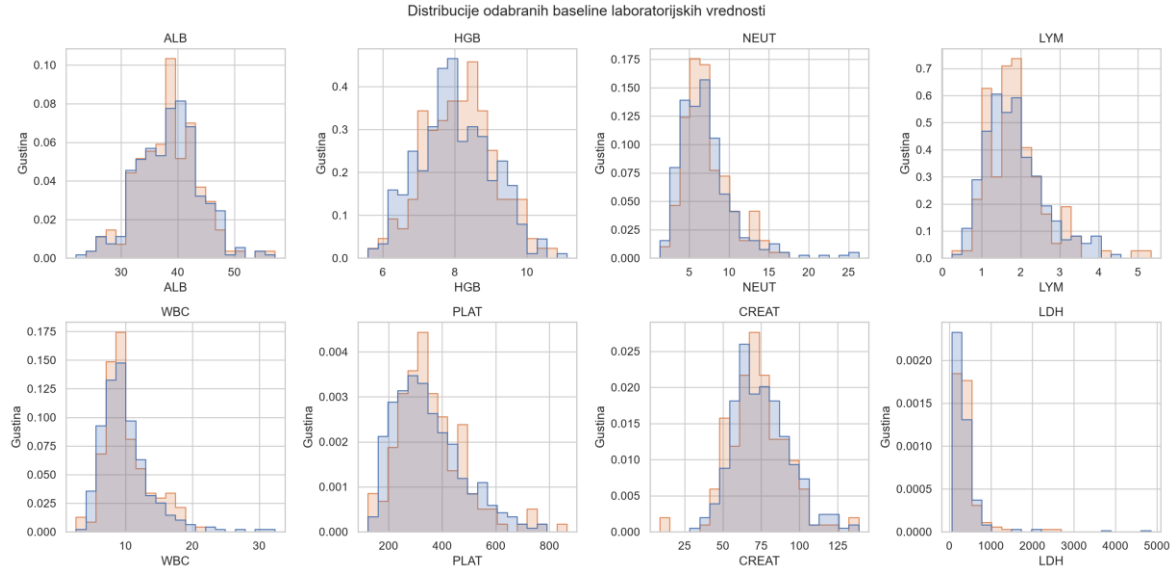


Слика 3. Проценат недостајућих вредности по атрибуту.

Импутација је део pipeline-а. За сваки fold медијана и најчешћа категорија процењују се само на тренинг делу тог fold-а. Иста логика важи за коначну поделу: статистике тест скупа не утичу на претпроцесирање. Индикатори недостатка омогућавају моделу да представи евентуалну разлику између измерене и импутиране вредности, али не доказују разлог због којег мерење недостаје.

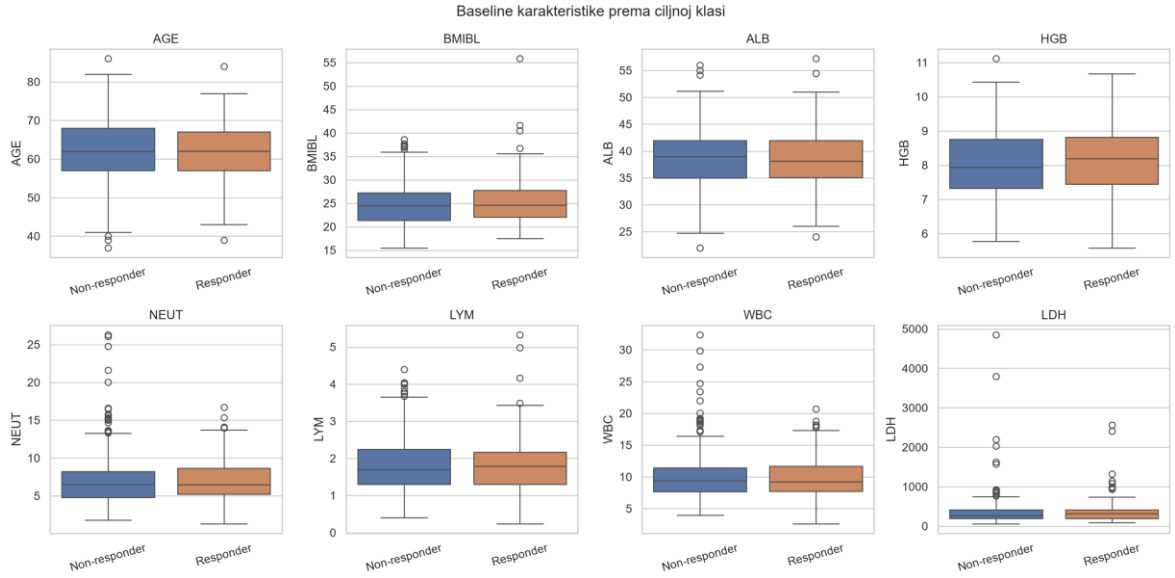
7.3. Нумеричке расподеле и униваријантна поређења

Лабораторијске вредности показале су различите степене асиметрије и присуство екстремних опсервација. Вредности нису ручно „пеглане" на основу исхода. Припадност baseline мерењу и јединица проверени су пре формирања матрице, док је скалирање извршено унутар модела.



Слика 4. Расподеле одабраних baseline лабораторијских показатеља.

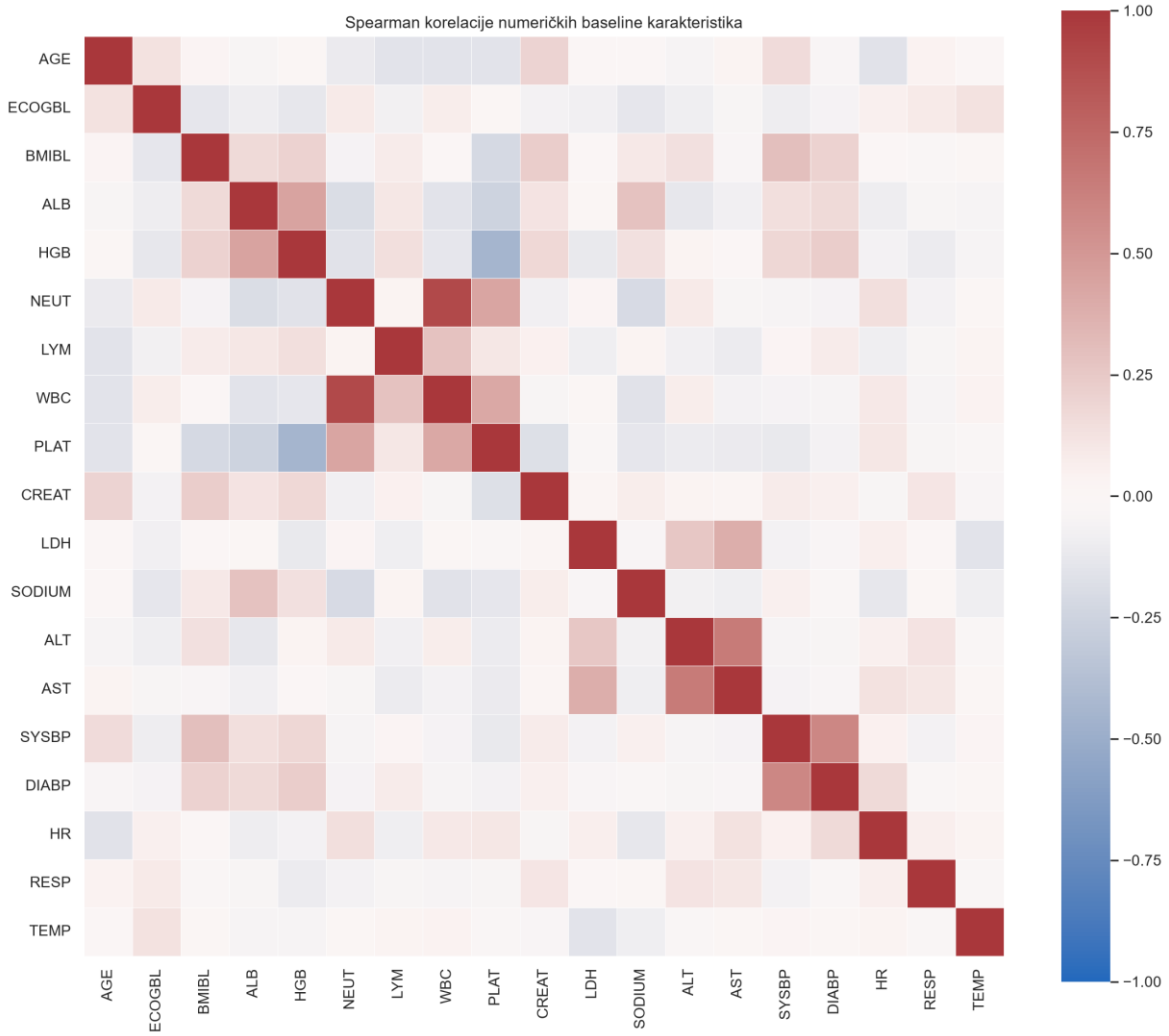
Boxplot прикази показују велико преклапање класа. Mann–Whitney тестови спроведени су за 19 нумеричких карактеристика, а p-вредности кориговане Benjamini–Hochberg поступком. Ниједна карактеристика није имала кориговану q-вредност мању од 0,05. Овај налаз не значи да ниједна варијабла нема било какву повезаност, већ да у доступном узорку није пронађен јак и стабилан универијантни сигнал након контроле вишеструког тестирања.



Слика 5. Поређење одабраних нумеричких атрибута према исходу.

7.4. Корелације

Spearman корелација коришћена је због могуће асиметрије и нелинеарних монотоних односа. Очекиване корелације постоје између сродних параметара крвне слике и телесне грађе, али матрица не показује једну доминантну осу која би јасно раздвојила исходе. Корелација међу предикторима није исто што и повезаност са target-ом. Код логистичке регресије регуларизација ублажава нестабилност услед корелисаних кодираних атрибута.



Слика 6. Spearman корелациона матрица нумеричких карактеристика.

8. РАЗВОЈ И ЕВАЛУАЦИЈА МОДЕЛА

8.1. Експериментални дизајн

Кохорта од 477 пацијената подељена је стратификовано у односу 80:20, са random_state=42. Тренинг скуп садржао је 381, а независни тест скуп 96 пацијената. Тест скуп није коришћен за избор алгоритма, хиперпараметара, прага или начина претпроцесирања.

Свих пет алгоритама користило је исти ColumnTransformer и исте fold-ове петоструке стратификоване унакрсне валидације. GridSearchCV је рангирао конфигурације према средњој CV ROC AUC вредности. Elastic Net логистичка регресија остварила је највиши средњи CV ROC AUC од 0,540 и изабрана је пре отварања тест резултата. Оптимална конфигурација користила је C=1, l1_ratio=0,9 и balanced тежине класа.

8.2. Резултати унакрсне валидације

Табела 4. Резултати петоструке унакрсне валидације на тренинг скупу.

Модел	CV ROC AUC	SD	Training ROC AUC
Logistic Regression	0.536	0.079	0.701
Elastic Net Logistic Regression	0.540	0.079	0.701
Random Forest	0.492	0.046	0.967
SVM	0.495	0.058	0.632
XGBoost	0.491	0.050	0.999

SD представља стандардну девијацију ROC AUC резултата добијених кроз пет валидационих fold-ова и показује колико учинак модела варира између различитих подела тренинг скупа. Elastic Net и стандардна логистичка регресија имале су готово једнаке CV резултате, док су Random Forest и XGBoost показали велики јаз између тренинг и валидационог учинка. Elastic Net је задржан због највишег CV просека и регуларизације која је прикладна за мали узорак и проширени простор након One-Hot кодирања.

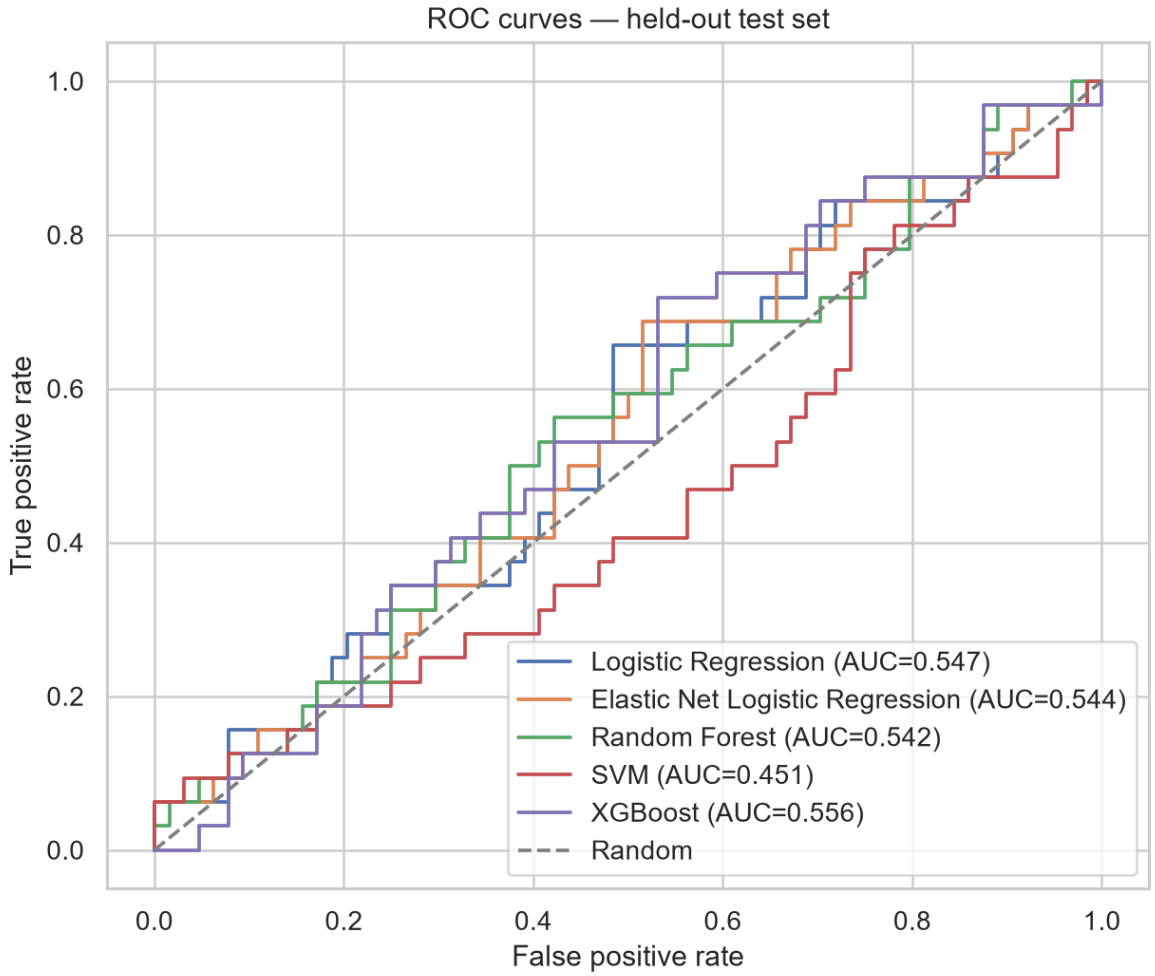
8.3. Комплетна евалуација на независном тест скупу

Табела 5. Дискриминационе, класификационе и калибрационе метрике на независном тест скупу.

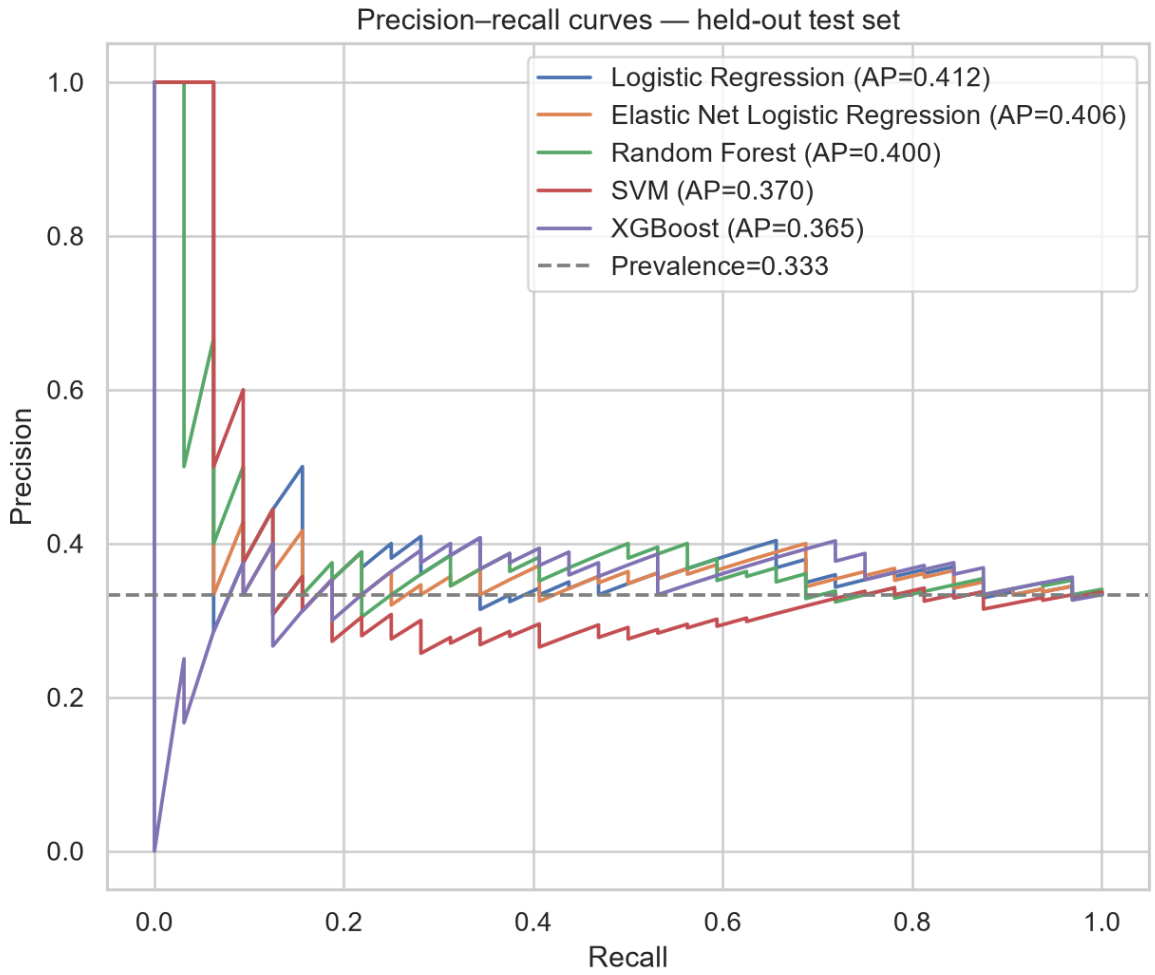
Модел	ROC AUC	PR AUC	Sens.	Spec.	Prec.	F1	Bal. Acc.	Brier	ECE
Logistic Regression	0.547	0.412	0.156	0.875	0.385	0.222	0.516	0.233	0.102
Elastic Net Logistic Regression	0.544	0.406	0.531	0.516	0.354	0.425	0.523	0.263	0.171
Random Forest	0.542	0.400	0.062	0.969	0.500	0.111	0.516	0.222	0.059
SVM	0.451	0.370	0.000	1.000	0.000	0.000	0.500	0.224	0.079
XGBoost	0.556	0.365	0.281	0.766	0.375	0.321	0.523	0.251	0.139

Sens. означава sensitivity/recall позитивне класе, Spec. specificity, Prec. precision, а Bal. Acc. balanced accuracy. Колона Калибр. (ECE) означава очекивану грешку калибрације; за Brier score и ECE мања вредност је повољнија. Све класификационе метрике израчунате су при унапред фиксираном прагу 0,5. Матрице конфузије, које приказују TN, FP, FN и TP за сваки модел, дате су одвојено на Слици 9.

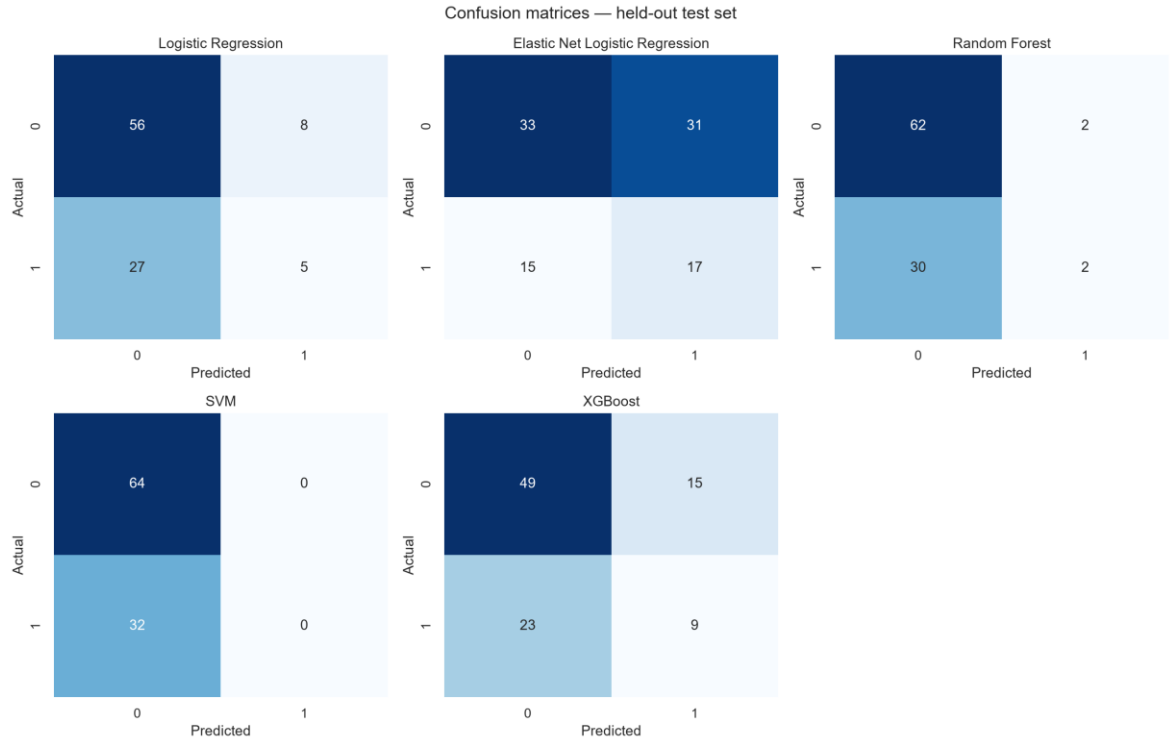
Elastic Net је препознао 17 од 32 responder-а и имао највиши sensitivity 0,531 и F1 0,425, уз balanced accuracy 0,523. Стандардна логистичка регресија имала је нешто већи тест ROC AUC 0,547, али знатно мањи sensitivity 0,156. SVM accuracy 0,667 потиче од предвиђања искључиво већинске класе, што потврђују sensitivity и F1 једнаки нули.



Слика 7. ROC криве пет модела на независном тест скупу.



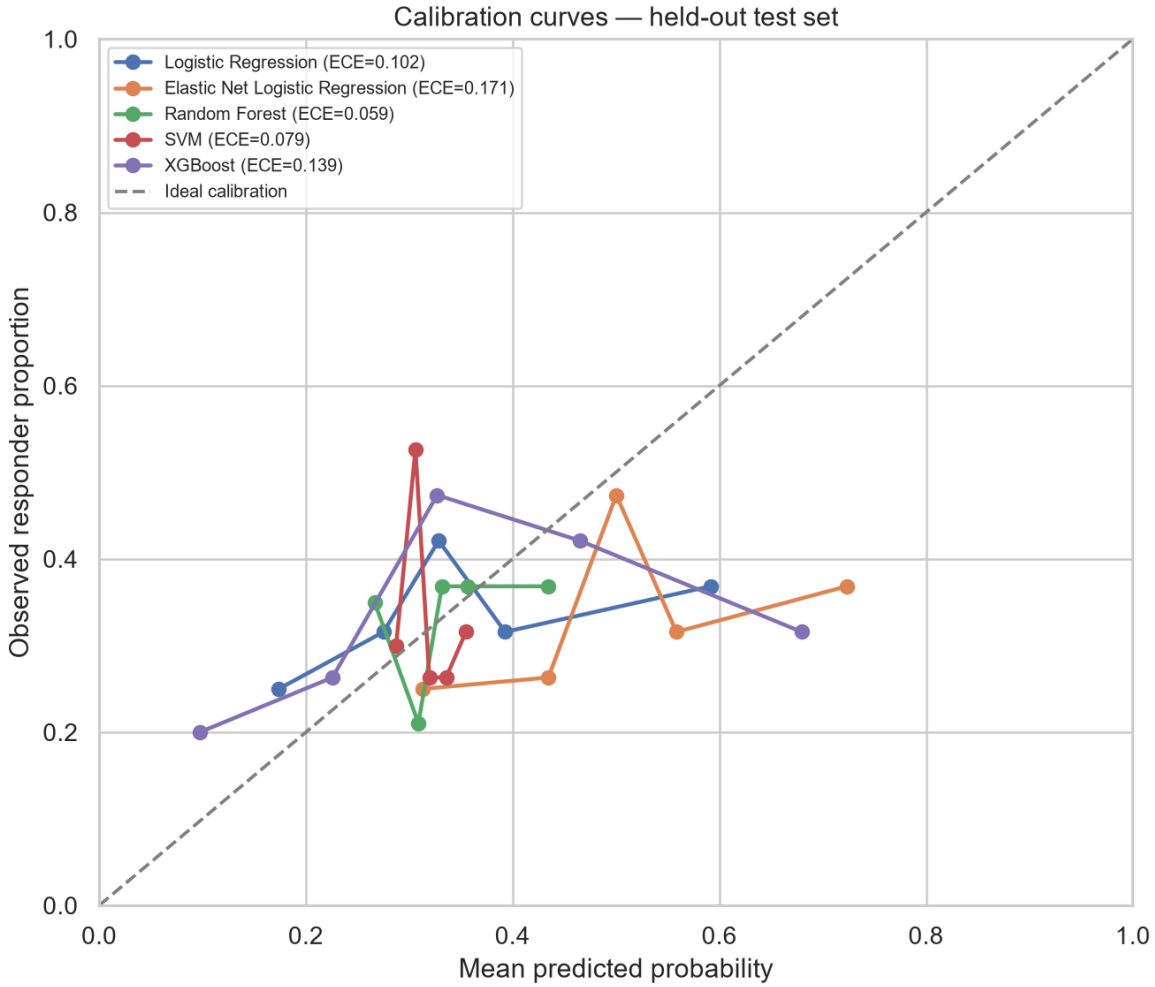
Слика 8. Precision–Recall криве пет модела на независном тест скупу.



Слика 9. Матрице конфузије пет модела при прагу вероватноће 0,5.

8.4. Калибрација предвиђених вероватноћа

Brier score обједињује тачност вероватносне прогнозе и калибрацију. Најмању вредност имао је Random Forest, 0,222, затим SVM 0,224 и стандардна логистичка регресија 0,233. Elastic Net је имао Brier score 0,263 и ECE 0,171. Његова боља осетљивост при прагу 0,5 зато не значи да су саме вероватноће оптимално калибрисане.



Слика 10. Калибрационе криве пет модела у пет квантилних интервала тест скупа.

Криве су израчунате на само 96 тест пацијената, приближно 19 по интервалу, па су локална одступања очекивано нестабилна. Зато се калибрација тумачи заједно са Brier score и ECE, а не на основу једне тачке криве. За будућу примену било би потребно проверити и по потреби кориговати калибрацију на независној кохорти.

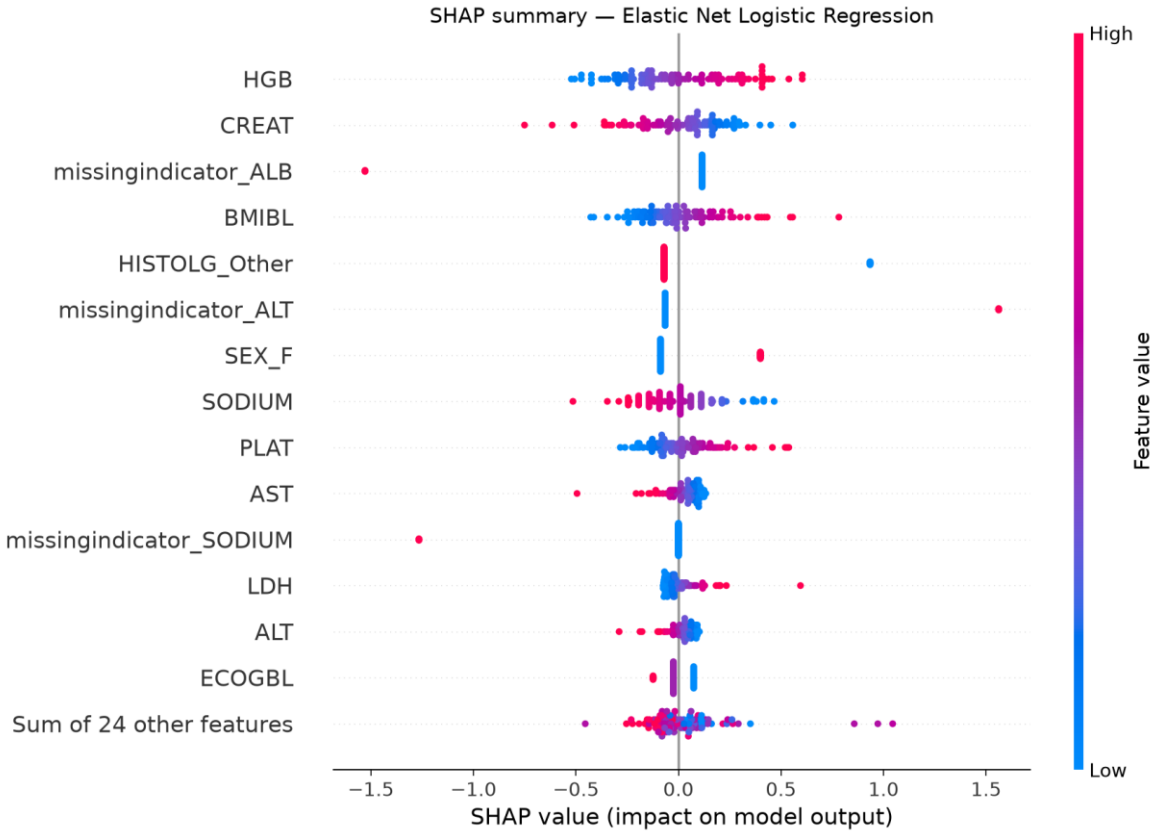
8.5. Неизвесност и избор финалног модела

За ROC AUC израчунати су 95% bootstrap интервали поверења: Logistic Regression: 0.419–0.670; Elastic Net Logistic Regression: 0.417–0.669; Random Forest: 0.416–0.663; SVM: 0.328–0.582; XGBoost: 0.435–0.674. Интервали су широки и међусобно се преклапају, што одговара ограниченој величини тест скупа. Избор Elastic Net модела заснива се на тренинг CV резултату и регуларизацији, а не на накнадном избору највеће тест метрике.

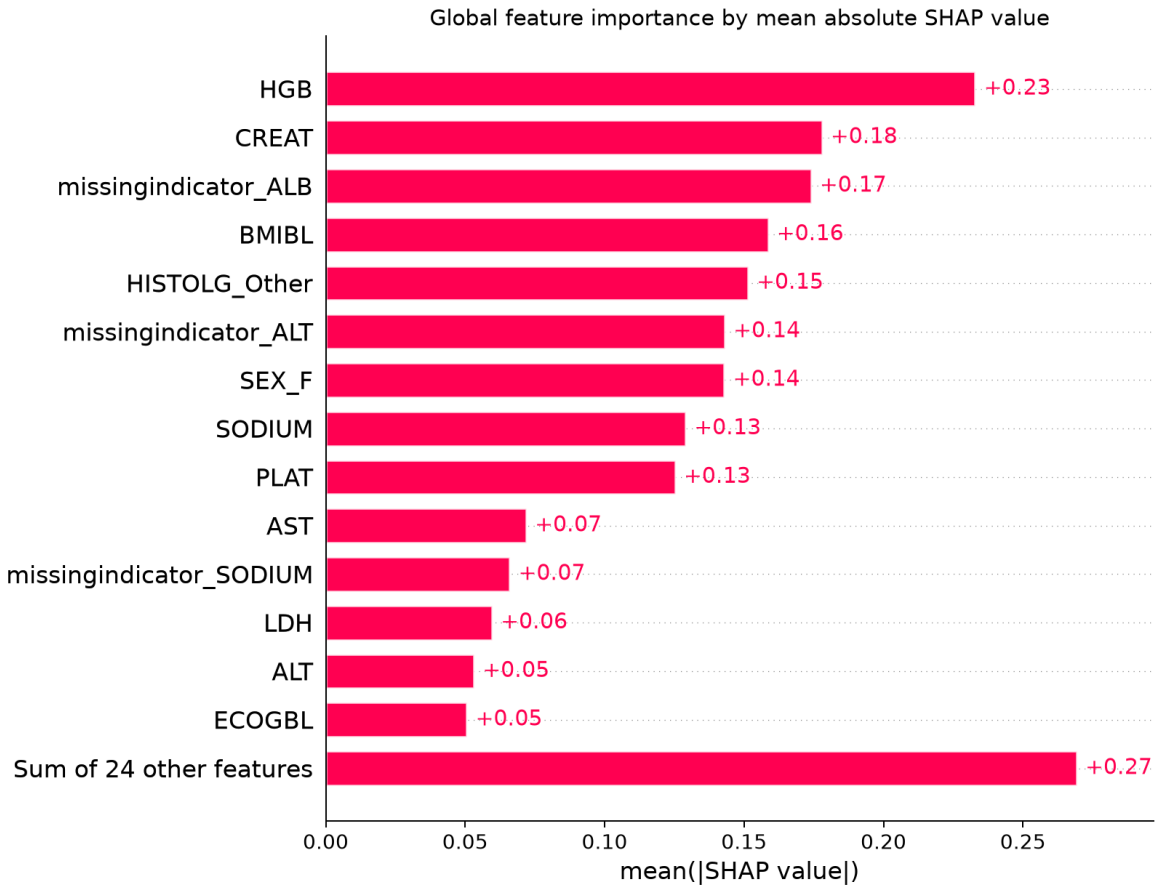
Модел за евалуацију остао је обучен само на 381 пацијенту. Одвојени deployment артефакт за апликацију поново је обучен на свих 477 пацијената са фиксираном конфигурацијом; тест метрике нису поново рачунате на том моделу.

8.6. SHAP анализа изабраног модела

SHAP LinearExplainer примењен је на трансформисане податке независног тест скупа. Према средњој апсолутној SHAP вредности, највећи допринос понашању модела имали су HGB, CREAT, индикатор недостајуће ALB вредности, BMIBL, категорија HISTOLG_Other, индикатор недостајућег ALT, пол, SODIUM и PLAT. Овај редослед описује начин на који модел користи расположиве податке и не представља доказ клиничке важности или узрочности [10].

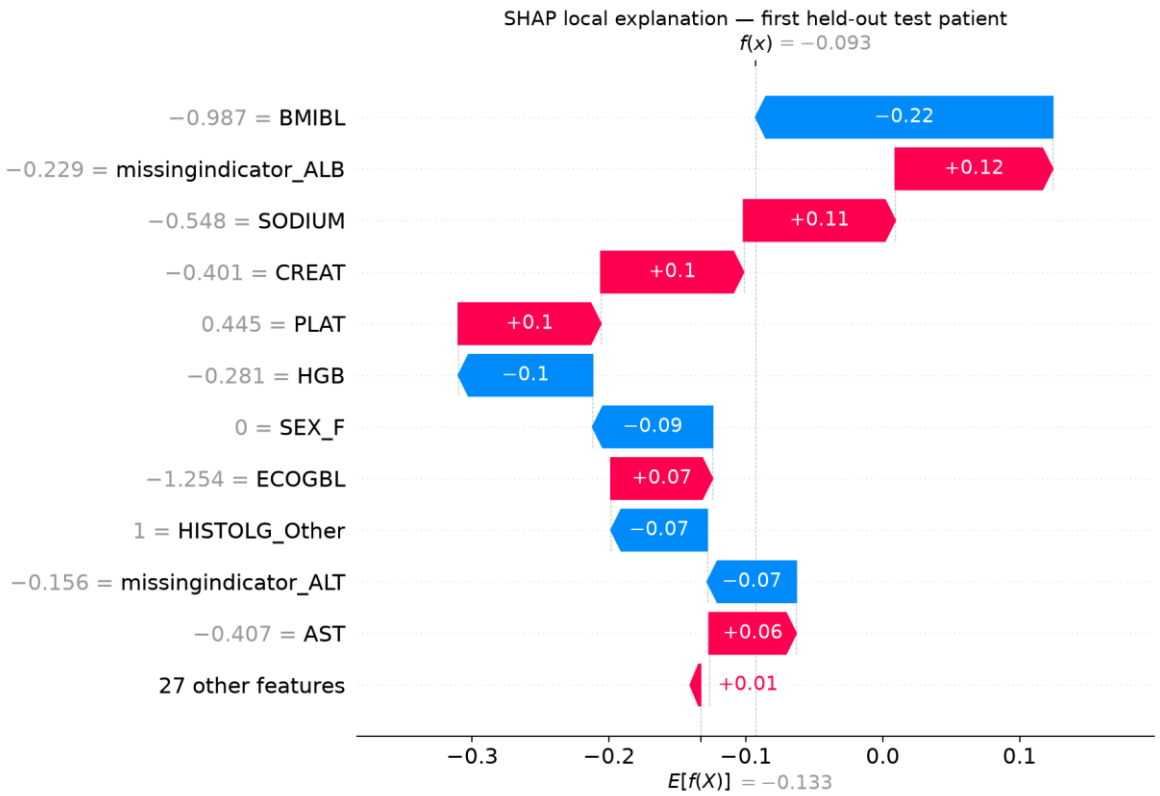


Слика 11. SHAP beeswarm приказ смера и величине доприноса атрибута на тест скупу.



Слика 12. Глобална важност атрибута према средњој апсолутној SHAP вредности.

Beeswarm приказ показује да веће стандардизоване вредности HGB и BMIBL углавном померају скор ка responder класи, док веће вредности CREAT и SODIUM чешће делују у супротном смеру. Индикатори недостајућих вредности захтевају посебан опрез: њихов допринос може одражавати образац мерења у конкретној студији, а не биолошки механизам.



Слика 13. Локално SHAP waterfall објашњење за једног пацијента из тест скупа.

Waterfall приказ почиње од очекиваног излаза модела и сабира позитивне и негативне SHAP доприносе до коначног линеарног скора. Приказане вредности су трансформисане вредности након импутације, стандардизације и One-Hot кодирања. Локално објашњење је проверљиво и адитивно, али не сме бити протумачено као препорука терапије.

9. РАЗВОЈ ВЕБ-АПЛИКАЦИЈЕ

9.1. Циљ и архитектура система

Веб-апликација је развијена као вишекорисnички информациони систем за евиденцију пацијената и покретање изабраног модела. За разлику од почетне верзије, која је садржала један формулар и тренутни приказ резултата, актуелна верзија обухвата пријаву и регистрацију лекара, административно одобравање налога, регистар псеудонимизованих пацијената, временску линију налаза, историју процена, локално објашњење, претрагу сличних случајева и извоз PDF извештаја.

Систем је реализован као слојевита целина. Презентациони слој чине Jinja2 HTML шаблони, Bootstrap компоненте и прилагођени CSS. Апликативни слој реализован је у FastAPI оквиру и садржи руте, проверу приступа, валидацију форме, позив моделског pipeline-а и припрему података за приказ. Слој података користи SQLite базу, док се модел и његова шема учитавају из засебних артефаката. Оваква подела спречава мешање корисничког интерфејса, пословних правила и ML логике.

При покретању се једном учитавају `deployment_model.joblib`, `model_metadata.json`, `input_schema.json` и развојна кохорта потребна за проналажење сличних случајева. Модел се не обучава током HTTP захтева. Зато свака процена користи исту закључану комбинацију претпроцесирања, коефицијената и прага, што обезбеђује поновљив резултат за исти улаз.

9.2. Регистрација, пријава и улоге корисника

Систем подржава улоге лекар и администратор. Нови лекар попуњава регистрациону форму са именом, корисничким именом и лозинком. Налог се уписује као неактиван и не може се користити пре административног одобрења. Администратор на посебној страници види регистроване кориснике, број налога који чекају одобрење и контроле за активирање или деактивирање приступа. Тиме регистрација не доводи аутоматски до приступа подацима.

Лозинка се не чува у отвореном облику. Примењује се PBKDF2-HMAC са SHA-256 функцијом, случајно генерисаном соли и 240.000 итерација. При пријави се поново израчунава извод и пореди функцијом константног времена. После успешне пријаве сервер формира временски ограничен, HMAC потписан идентификатор сесије и шаље га као `HttpOnly` колачић са `SameSite=Strict` политиком. Овај механизам је примерен локалном прототипу; продукционо окружење би захтевало HTTPS, тајну из безбедног складишта, CSRF заштиту и централизовано управљање идентитетом.

Ауторизација се проверава на серверу при сваком заштићеном захтеву. Лекар приступа само пацијентима чији `doctor_id` одговара његовом налогу. Административне руте захтевају улогу `admin`, а корисник не може сам себи променити статус. Провера у интерфејсу служи само за приказ навигације; стварна контрола се увек спроводи у backend-у.

9.3. Модел података и SQLite база

База садржи пет логичких целина. Табела `doctors` чува корисничко име, hash лозинке, пуно име, улогу, статус налога и време креирања. Табела `patients` садржи псеудонимизовану шифру, иницијале, годину рођења, пол, напомену и власника записа. Табела `observations` представља појединачни клинички запис са датумом, врстом,

вредностима 18 атрибута у JSON облику и напоменом. Табела `predictions` чува резултат модела, упозорења, објашњење, сличне случајеве, употребљени улаз, праг и верзију артефакта. Табела `audit_log` бележи важне операције над системом.

Одвајање налаза од процене је намерно. Један baseline запис може бити повезан са више сачуваних процена, на пример после промене верзије система, а свака процена задржава тачно оне улазне вредности које су употребљене. Накнадна измена профила зато не мења историјски резултат. Овај образац обезбеђује следљивост и спречава да корисник касније види резултат без контекста у којем је настао.

SQLite је изабран јер не захтева посебан сервер и довољан је за једнокорисничку или локалну демонстрацију. Трансакције обезбеђују да упис налаза, процене или промене статуса буде атомичан. За више истовремених корисника и продукциони рад примеренији би био PostgreSQL, са миграцијама шеме, резервним копијама и детаљнијим ограничењима референцијалног интегритета.

9.4. Регистар пацијената и временска линија

После пријаве лекар добија контролну таблу са бројем пацијената, сачуваних процена, непотпуних улаза и ознаком активног алгоритма. Радна листа приказује недавно коришћене профиле. Регистар омогућава претрагу по pseudonimizovanoj шифри или иницијалима, док се нови пацијент креира без имена, адресе и других директних идентификатора. Шифра облика `PAC-00001` генерише се у систему.

Профил пацијента обједињује основне податке, клиничку напомену, налазе и историју процена. Налази су приказани хронолошки. Врста `baseline` означава запис који сме бити прослеђен моделу, док `followup` служи само за временску линију. Backend одбија покретање процене над контролним записом. Ово ограничење није само интерфејсно правило, већ заштита од временског цурења података, пошто је модел обучен искључиво над вредностима доступним пре почетка терапије.

Формулар је подељен на основне и клиничке податке, крвну слику и биохемију. Нумеричка поља приказују јединицу, медијану и развојни опсег. Категоријска поља се генеришу из `input_schema.json`, па интерфејс и модел користе исти скуп категорија. Празна вредност се чува као `null` и обрађује импутацијом унутар pipeline-а.

9.5. Извршавање процене и конзистентност pipeline-а

При покретању процене backend прво проверава власништво над пацијентом и врсту изабраног налаза. Вредности се распоређују према фиксној листи `FEATURES` и формира се једноредни `DataFrame`. Позив `predict_proba` покреће исти scikit-learn pipeline који је употребљен у евалуацији: нумеричку импутацију и скалирање, категоријску импутацију и One-Hot кодирање, а затим логистичку регресију.

Процењена вероватноћа пореди се са прагом 0,5. Поред класе и вероватноће, систем израчунава комплетност улаза и број импутираних атрибута. За нумеричку вредност изван минимума и максимума развојне кохорте формира се упозорење, али се захтев не одбацује. Ако недостаје најмање седам атрибута, додаје се јасна порука о нарочитој непоузданости. Тако се разликују формално невалидни подаци од технички обрадивих, али методолошки ризичних улаза.

Резултат се чува као нов, неизмењив запис са идентификатором лекара, временом, улазом, прагом, називом алгоритма и скраћеним SHA-256 hash-ом моделског

артефакта. Hash не мери квалитет модела, већ омогућава проверу којом бинарном верзијом је резултат добијен.

9.6. Локално објашњење резултата

За изабрану логистичку регресију локално објашњење може се израчунати директно. Претпроцесирани вектор једног пацијента множи се коефицијентима класификатора. Производ сваке компоненте представља њен допринос log-odds скору, а збир доприноса и слободног члана реконструише моделски резултат. Интерфејс приказује осам доприноса са највећом апсолутном вредношћу, смер, техничку ознаку и стварну или импутирану вредност.

Позитиван допринос значи да компонента повећава скор responder класе у односу на полазну вредност модела, а негативан да га смањује. Он није доказ узрочности, медицинске важности нити ефекта терапијске интервенције. Зато систем користи формулације „повећава процену" и „смањује процену", а не „узрокује одговор". Индикатори недостајања користе се у прорачуну, али су изостављени из главне листе како приказ не би погрешно представио импутирану вредност као клиничку карактеристику.

9.7. Проналажење сличних случајева

Систем уз резултат приказује пет најближих псеудонимизованих случајева из развојне кохорте. Нови улаз и кохорта трансформишу се истим претпроцесором, чиме нумеричке вредности добијају упоредиву скалу, а категорије бинарну репрезентацију. За сваки развојни пример рачуна се Еуклидско растојање у том простору и бира пет најмањих вредности.

За суседа се приказују ранг, генерисана шифра, растојање, старост, ECOG, хистологија и стварно забележена класа. Ознаке високе, средње и ниске сличности одређују се према квартилним границама расподеле растојања за конкретан упит. Систем намерно не приказује произвољан „проценат сличности", јер растојање нема природну процентуалну интерпретацију.

Исходи суседа не улазе у логистичку предикцију и не представљају додатни гласачки модел. Њихова улога је контекстуална: корисник може видети да ли се улаз налази близу примера познатих развојном скупу. Мера зависи од претпроцесирања, избора атрибута и густине кохорте, па се сличан случај не сме тумачити као клинички еквивалентан пацијент.

9.8. Извештај, историја и audit траг

Свака процена остаје у историји профила са вероватноћом, класом, временом и верзијом артефакта. Страница резултата обједињује кружни приказ вероватноће, праг, комплетност, доприносе, упозорења и сличне случајеве. Из истог записа генерише се PDF извештај, па документ и приказ у browser-у користе исте сачуване податке.

PDF садржи псеудонимизовану шифру пацијента, датум baseline налаза, лекара, резултат, највеће доприносе, сличне случајеве и ознаку модела. Извештај не садржи директне идентификаторе. На свакој верзији остаје напомена да систем није медицинско средство и да резултат не сме бити основ за избор или промену терапије.

Audit табела бележи пријаву, креирање пацијента и налаза, покретање процене, извоз и административну промену статуса. Тренутни интерфејс не приказује сиров audit

log лекару, али запис остаје доступан за техничку проверу. За продукциони систем било би потребно дефинисати период чувања, заштиту од измене и посебну улогу за безбедносни надзор.

9.9. Валидација и безбедносна ограничења

Валидација се спроводи на више нивоа. HTML контрола ограничава основни формат, backend конвертује нумеричке вредности и проверава категорије према шеми, а pipeline захтева тачан скуп и редослед колона. SQL упити користе параметре уместо спајања текста, чиме се избегава основни облик SQL injection напада. Колачић сесије није доступан JavaScript-у.

Псеудонимизација смањује ризик, али не претвара клинички запис аутоматски у анониман податак. Комбинација године рођења, налаза и ретких карактеристика и даље може бити осетљива. Зато је апликација ограничена на локалну демонстрацију и не треба уносити стварне идентификационе податке. Продукциона верзија захтевала би HTTPS, енкрипцију базе и резервних копија, ротацију тајни, CSRF заштиту, политику лозинки, ограничење покушаја пријаве и формалну анализу приватности.

Апликација јасно раздваја техничку исправност од клиничке валидности. Успешан HTTP одговор доказује да су компоненте повезане, али не да је процена довољно тачна за медицинску одлуку. Слаба тест дискриминација и изостанак екстерне валидације остају главна ограничења без обзира на функционалност интерфејса.

9.10. Тестирање интегрисаног система

Апликативни тестови користе FastAPI `TestClient` и пролазе кроз стварне руте без покретања спољног мрежног сервера. Проверени су приказ login и регистрационе стране, пријава постојећег корисника, одбијање неактивног налога, административни приступ, креирање пацијента, упис baseline налаза, покретање процене, чување резултата и генерисање валидне PDF датотеке.

Посебан интеграциони сценарио обухвата цео ток: пријава → пацијент → baseline налаз → процена → објашњење → слични случајеви → PDF. Додатно је проверено да све главне HTML руте и `/health` враћају статус 200 за овлашћеног корисника. Тестови не користе тест скуп за ново подешавање модела и не мењају раније пријављене евалуационе метрике.

За потпунију верификацију требало би увести засебну тест базу, unit тестове за hash лозинке и потпис сесије, тестове конкурентних уписа, CSRF тестове, проверу приступа туђем пацијенту и аутоматско покретање у CI окружењу. Визуелни regression тестови могли би да открију промене распореда на desktop и мобилним ширинама.

9.11. Пројектовање интерфејса и даљи развој

Интерфејс користи сталну бочну навигацију, јасну хијерархију наслова и картице за кључне бројеве. Техничке ознаке атрибута су секундарне у односу на описне називе, док су јединице и развојни опсези видљиви уз унос. Резултат је одвојен од формулара, вероватноћа је приказана бројем и графички, а боја није једини носилац значења. Responsive правила прилагођавају распоред ужем екрану.

Даљи развој треба усмерити на инжењерску поузданост, а не на додавање сложенијег алгоритма без нових података. Приоритети су PostgreSQL и миграције шеме, CSRF и rate-limit заштита, формално управљање верзијама модела,

структурисано логовање, тестна база и CI поступак. За евентуално повезивање са лабораторијским системом потребан је adapter који би контролисао код параметра, јединицу и време мерења.

ML део би требало проширивати тек после прикупљања независне кохорте и информативнијих претерапијских атрибута. Тада би било оправдано испитати калибрацију, стабилност објашњења, праведност по подгрупама и data drift. До тада апликација остаје технички заокружена демонстрација целог software и ML lifecycle-a, уз експлицитно ограничење да није клинички валидиран систем.

10. ДИСКУСИЈА

Главни налаз рада је да одабране рутинске baseline карактеристике нису омогућиле поуздану индивидуалну предикцију објективног одговора на гемцитабин и цисплатин. Највећи тест ROC AUC био је 0,556, а ниједан bootstrap интервал поверења није искључио 0,5. Према томе, разлике у тачкастим проценама алгоритама мање су важне од заједничког закључка о слабом сигналу и великој неизвесности.

Овакав резултат није неуспех поступка. Коректно спроведена анализа мора омогућити и закључак да расположиви подаци нису довољни. Супротан приступ — укључивање посттерапијских мерења, избор модела на тест скупу или извештавање само accuracy — произвео би привидно бољу, али методолошки неважећу слику. TRIPOD наглашава транспарентно извештавање развоја и валидације предиктивних модела, док PROBAST систематизује ризике пристрасности у доменима учесника, предиктора, исхода и анализе [6], [7].

Постоји више могућих разлога за слаб учинак. Прво, објективни туморски одговор зависи од биологије тумора која није у потпуности представљена основном демографијом и рутинским лабораторијама. Молекуларни, радиомски или детаљни показатељи туморског оптерећења могли би носити додатну информацију, али нису били део одабраног једноставног проблема. Друго, 477 пацијената је ограничен узорак за откривање слабих интеракција, нарочито када је само 158 позитивних примера. Треће, поједине категорије су веома ретке, што онемогућава стабилно учење њиховог ефекта.

Четврто, бинаризација губи део клиничке информације. SD и PD нису идентични исходи, као што ни CR и PR нису истог интензитета. Ипак, бинарна дефиниција је усклађена са објективним одговором и погодна за јасан дипломски задатак. Анализа више класа или времена до прогресије представљала би различит исход и захтевала нови дизајн, а не само замену етикете.

Пето, процена је интерна. Стратификована унакрсна валидација и одвојени тест скуп смањују оптимизам, али сви пацијенти потичу из исте студије. Дискриминација и калибрација су у раду процењене интерно, док су екстерна валидација, клиничка корисност, правичност по подгрупама и анализа утицаја одлуке неопходни пре било каквог разматрања практичне употребе.

XGBoost и Random Forest илуструју ризик да сложенији модел није нужно бољи. Њихов готово савршен тренинг учинак, уз валидациони ROC AUC око 0,49, указује на прекомерно прилагођавање. Elastic Net је имао највиши CV просек 0,540 и sensitivity 0,531 на тесту, али Brier score 0,263 и ECE 0,171 показују да процењене вероватноће још нису довољно добро калибрисане за клиничко тумачење.

Избор прага 0,5 коришћен је за стандардно поређење, али оптималан праг зависио би од последица лажно позитивних и лажно негативних одлука. У овом раду праг није оптимизован на тесту јер за то нема дефинисаног клиничког критеријума. Чак и са другим прагом ROC AUC би остао исти, а слаб рангирајући учинак не би био отклоњен.

Апликација има образовну и демонстрациону вредност: показује како се модел серијализује, валидирају улази и приказује локално објашњење. Њено постојање не повећава доказну снагу модела. Намерно раздвајање `best_model` артефакта за евалуацију и `deployment_model` артефакта за прототип спречава мешање тест резултата са моделом поново обученим на свим подацима.

Будући рад треба усмерити на проспективно дефинисане предикторе, већи број пацијената и независну валидацију. Могу се размотрити квантитативне baseline карактеристике туморског оптерећења, пажљиво временски ограничена медицинска историја и биомаркери доступни пре терапије. Сваки додатни извор мора проћи исту проверу времена доступности. Побољшање метрика не сме бити резултат додавања информација које настају након исхода.

11. ЗАКЉУЧАК

У раду је развијен комплетан поступак анализе и предикције одговора на терапију код пацијената са стадијумом IV планоцелуларног NSCLC. Из девет SQUIRE ADaM табела формирана је кохорта од 477 пацијената са дефинисаним исходом. Потпун и делимичан одговор представљали су responder класу, а стабилна и прогресивна болест non-responder класу. Записи без процењивог исхода нису произвољно сврставани.

Изабрано је 18 baseline карактеристика, а све посттерапијске и исходне информације искључене су ради спречавања цурења. Претпроцесирање је спроведено унутар pipeline-а, подаци су стратификовано подељени, а пет алгоритама подешено је унакрсном валидацијом само на тренинг скупу. Поред дискриминационих и класификационих метрика, процењени су Brier score, ECE и калибрационе криве.

Elastic Net логистичка регресија изабрана је за прототип јер је имала највиши средњи CV ROC AUC од 0,540. На тест скупу остварила је ROC AUC 0,544, PR AUC 0,406, sensitivity 0,531, specificity 0,516, F1 0,425 и balanced accuracy 0,523. Ови резултати показују да регуларизација побољшава равнотежу препознавања класа, али интервали поверења и калибрационе метрике и даље захтевају опрез и додатну валидацију.

Развијена веб-апликација успешно повезује унос, претпроцесирање, Elastic Net модел, вероватноћу и локално објашњење. SHAP анализа додатно повезује глобалну важност атрибута са објашњењем појединачне процене. Апликација представља доказ техничког концепта, не медицински уређај. Даље побољшање захтева информативније baseline податке, већи узорак, спољашњу валидацију и по потреби засебну калибрацију модела.

ЛИТЕРАТУРА

[1] N. Thatcher et al., “Necitumumab plus gemcitabine and cisplatin versus gemcitabine and cisplatin alone as first-line therapy in patients with stage IV squamous non-small-cell lung cancer (SQUIRE): an open-label, randomised, controlled phase 3 trial,” *The Lancet Oncology*, vol. 16, no. 7, pp. 763–774, 2015, doi: 10.1016/S1470-2045(15)00021-2.

[2] Project Data Sphere, “SQUIRE control-arm dataset,” doi: 10.34949/05tc-jx78.

[3] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[4] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995, doi: 10.1007/BF00994018.

[5] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[6] G. S. Collins, J. B. Reitsma, D. G. Altman, and K. G. M. Moons, “Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis (TRIPOD),” *BMJ*, vol. 350, g7594, 2015, doi: 10.1136/bmj.g7594.

[7] R. F. Wolff et al., “PROBAST: A tool to assess the risk of bias and applicability of prediction model studies,” *Annals of Internal Medicine*, vol. 170, no. 1, pp. 51–58, 2019, doi: 10.7326/M18-1376.

[8] S. E. Davis et al., “A non-technical framework for identifying and mitigating label leakage in machine learning models with electronic health record data,” *Journal of the American Medical Informatics Association*, vol. 31, no. 1, pp. 274–280, 2024, doi: 10.1093/jamia/ocad178.

[9] T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLOS ONE*, vol. 10, no. 3, e0118432, 2015, doi: 10.1371/journal.pone.0118432.

[10] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems 30*, 2017, pp. 4765–4774.

[11] H. Zou and T. Hastie, “Regularization and variable selection via the elastic net,” Journal of the Royal Statistical Society: Series B, vol. 67, no. 2, pp. 301–320, 2005, doi: 10.1111/j.1467-9868.2005.00503.x.